



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی
مهندسی کامپیوتر

موتور جستجوی هوشمند وب

نگارش

علی هاشمیان

استاد راهنما

دکتر حمید بیگی

خرداد ۱۴۰۵



سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

چکیده

نگارش پایان‌نامه علاوه بر بخش پژوهش و آماده‌سازی محتوا، مستلزم رعایت نکات فنی و نگارشی دقیقی است که در تهیه‌ی یک پایان‌نامه‌ی موفق بسیار کلیدی و مؤثر است. از آن جایی که بسیاری از نکات فنی مانند قالب کلی صفحات، شکل و اندازه‌ی قلم، صفحات عنوان و غیره در تهیه‌ی پایان‌نامه‌ها یکسان است، با استفاده از نرم‌افزار حروف‌چینی زی‌تک و افزونه‌ی زی‌پرشین یک قالب استاندارد برای تهیه‌ی پایان‌نامه‌ها ارائه گردیده است. این قالب می‌تواند برای تهیه‌ی پایان‌نامه‌های کارشناسی و کارشناسی ارشد و نیز رساله‌های دکتری مورد استفاده قرار گیرد. این نوشتار به طور مختصر نحوه‌ی استفاده از این قالب را نشان می‌دهد.

کلیدواژه‌ها: پایان‌نامه، حروف‌چینی، قالب، زی‌پرشین

فهرست مطالب

۱	مقدمه	۱
۱-۱	بیان مسئله	۱
۲-۱	اهمیت و ضرورت موضوع	۲
۳-۱	چالش‌های معماری استاندارد RAG در فضای وب	۳
۴-۱	اهداف پژوهش	۴
۵-۱	پرسش‌های پژوهش	۴
۶-۱	نوآوری و سهم کار	۵
۷-۱	روش کلی انجام کار	۵
۸-۱	ساختار پایان‌نامه	۶
۲	مفاهیم پایه و مبانی نظری	۷
۱-۲	موتورهای جستجوی سنتی	۷
۲-۲	مدل‌های زبانی بزرگ ^۱ (LLMs) و پاسخ‌گویی محاوره‌ای	۹
۳-۲	تولید افزوده شده با بازیابی ^۲ (RAG)	۱۰
۴-۲	تفاوت RAG کلاسیک با RAG مبتنی بر وب (چالش‌های اساسی)	۱۰
۵-۲	سامانه‌های مبتنی بر جستجوی وب (Search-Augmented LLMs) و ابزارهای API	۱۱
۶-۲	نقش تاریخچه گفتگو در پاسخ‌گویی محاوره‌ای	۱۲

^۱Large Language Models

^۲Retrieval-Augmented Generation

۷-۲	بازرتبه‌بندی ^۳ یا Re-ranking	۱۲
۸-۲	معیارهای ارزیابی سامانه‌ها ^۴	۱۲
۳	کارهای پیشین و تحلیل سامانه‌های موجود	۱۴
۱-۳	تحلیل سامانه‌ی پرپلکسیستی (پارادایم موتور پاسخ‌دهی)	۱۵
۲-۳	تحلیل سامانه‌ی گوگل (معماری SGE و ادغام گراف دانش)	۱۶
۳-۳	تحلیل مایکروسافت کوپایلت (معماری پرومیتوس)	۱۷
۴-۳	تحلیل تطبیقی سامانه‌های پیشرو	۱۷
۵-۳	تحلیل تئوریک بازرتبه‌بندی و تبیین شکاف پژوهشی	۱۷
۱-۵-۳	RAG تجاری در برابر RAG آکادمیک و شکاف‌های موجود	۱۸
۴	معماری و روش پیشنهادی	۲۰
۱-۴	مقدمه	۲۰
۲-۴	معماری کلی سامانه	۲۰
۱-۲-۴	منطق تصمیم‌گیر برای سوئیچ حالت‌ها	۲۱
۳-۴	مدیریت تاریخچه و بافتار	۲۱
۱-۳-۴	ذخیره‌سازی و بازیابی تاریخچه	۲۲
۲-۳-۴	تزریق بافتار به مدل	۲۲
۴-۴	خط لوله‌ی جست‌وجوی وب	۲۲
۱-۴-۴	ماژول بسط پرس‌وجو	۲۳
۲-۴-۴	لایه‌ی بازیابی اولیه	۲۳
۳-۴-۴	لایه‌ی بازرتبه‌بندی ترکیبی	۲۳
۴-۴-۴	تولید پاسخ نهایی و سیستم ارجاع‌دهی	۲۴
۵-۴	جزئیات فنی پیاده‌سازی	۲۵

³Re-ranking

⁴System Evaluation Metrics

۲۵	۴-۶ مزایا و محدودیت‌های روش پیشنهادی
۲۷	۵ نتایج جدید
۲۸	۶ نتیجه‌گیری
۲۹	مراجع
۳۴	واژه‌نامه
۳۶	آ مطالب تکمیلی

فهرست جداول

۱-۳ ماتریس فنی و تحلیل تطبیقی معماری سامانه‌های پاسخ‌گویی هوشمند ۱۸

فهرست تصاویر

فصل ۱

مقدمه

نخستین فصل این پایان‌نامه به معرفی مسئله، بیان اهمیت و ضرورت موضوع، تبیین چالش‌های موجود در معماری‌های رایج، اهداف پژوهش و در نهایت معرفی ساختار کلی پایان‌نامه می‌پردازد. در این فصل، تصویری جامع از انگیزه‌های انجام این تحقیق و مسیر پیش رو ارائه می‌گردد.

۱-۱ بیان مسئله

در سال‌های اخیر، ظهور و تکامل مدل‌های زبانی بزرگ^۱ تحولی بنیادین و پارادایم‌شیف‌چشمگیری در نحوه تعامل انسان با ماشین، پردازش زبان طبیعی و روش‌های دسترسی به اطلاعات ایجاد کرده است [۱]. با این وجود، پارادایم سنتی بازیابی اطلاعات و جستجو در وب همچنان با چالش‌ها و کاستی‌های جدی مواجه است. موتورهای جستجوی سنتی، عمدتاً بر اساس الگوریتم‌های تطبیق کلیدواژه^۲ و تحلیل پیوندها عمل می‌کنند [۲، ۳]. این سیستم‌ها به جای ارائه پاسخ نهایی و تحلیلی به کاربر، صرفاً فهرستی از پیوندها (لینک‌ها) را برمی‌گردانند که بار شناختی مطالعه، تجمیع و استخراج پاسخ نهایی را به طور کامل بر دوش کاربر قرار می‌دهد.

از سوی دیگر، مدل‌های زبانی بزرگ با وجود توانمندی شگرف در درک عمیق بافتار و تولید زبان طبیعی روان، دارای محدودیت‌های ذاتی و ساختاری مهمی هستند. نخستین محدودیت، اتکای این مدل‌ها به «دانش ایستا»^۳ است؛ به این معنا که حافظه پارامتریک^۴ آن‌ها محدود به داده‌هایی است که تا زمان پایان

^۱Large Language Models (LLMs)

^۲Keyword-matching

^۳Static Knowledge

^۴Parametric Memory

فاز آموزش^۵ دریافت کرده‌اند. به همین دلیل، این مدل‌ها در پاسخ‌گویی به پرسش‌هایی که نیازمند آگاهی از رویدادهای لحظه‌ای، اخبار روز و داده‌های بلادرنگ هستند، کاملاً ناتوان عمل می‌کنند [۴].

محدودیت دوم و به مراتب خطرناک‌تر، پدیده‌ای به نام «توهم»^۶ است. مدل‌های زبانی به گونه‌ای طراحی شده‌اند که همواره توالی کلمات بعدی را با بیشترین احتمال تولید کنند؛ بنابراین در صورت عدم آگاهی از فکت‌های واقعی پیرامون یک موضوع، ممکن است پاسخ‌هایی کاملاً ساختگی، نامعتبر اما با لحنی به شدت متقاعدکننده و ساختاریافته تولید نمایند [۵، ۶].

بر این اساس، مسئله اصلی پژوهش حاضر، غلبه بر محدودیت‌های متقابل هر دو سیستم (یعنی رویکرد منفعل موتورهای جستجوی سنتی و توهم‌زایی مدل‌های زبانی منفرد) از طریق طراحی، پیاده‌سازی و بررسی یک سامانه پاسخ‌گویی هوشمند است. سامانه‌ای عامل‌گونه که بتواند با تحلیل دقیق نیت کاربر و درک تاریخیچه تعاملات (گفتگوها)، پرسش‌های جستجوی بهینه‌ای تولید کرده، فضای وب را در لحظه کاوش کند و با بهره‌گیری از تکنیک‌های پیشرفته پردازش زبان و بازرتبه‌بندی^۷، پاسخی تحلیلی، به‌روز و کاملاً مستند (همراه با ارجاع به منابع) ارائه دهد.

۲-۱ اهمیت و ضرورت موضوع

با تغییر الگوی مصرف اطلاعات در عصر دیجیتال، سطح انتظارات کاربران از سیستم‌های بازیابی اطلاعات دگرگون شده است. کاربران امروزی انتظار دارند به جای جستجوی دستی در میان انبوهی از صفحات وب، پاسخ‌های مستقیم، دقیق، به‌روز و قابل استناد را در قالب یک گفتگوی محاوره‌ای و روان دریافت کنند. ترکیب موتورهای جستجو با هوش مصنوعی مولد^۸، راهکاری است که معماری‌های پیشگامی نظیر پرپلکسیتی^۹، بینگ کوپایلوت^{۱۰} و جستجوی هوشمند گوگل^{۱۱} به سوی آن حرکت کرده‌اند و اهمیت استراتژیک و تجاری این حوزه را در سطح جهانی به اثبات رسانده‌اند [۷، ۸، ۹].

ضرورت بنیادین انجام این پژوهش در این است که استفاده‌ی صرف و بدون پشتوانه از مدل‌های زبانی در حوزه‌های حساس (نظیر حوزه‌های پزشکی، حقوقی، علمی و خبری) که نیازمند دقت بالا و فکت‌های اثبات‌شده هستند، به دلیل خطرات ناشی از توهم مدل، غیرقابل اعتماد و بعضاً آسیب‌زا است. متصل کردن

^۵Training Cut-off

^۶Hallucination

^۷Reranking

^۸Generative AI

^۹Perplexity

^{۱۰}Bing Copilot

^{۱۱}Google AI Search

مدل زبانی به جریان اطلاعات پویای وب که اصطلاحاً اتصال به زمینه‌ی وب^{۱۲} نامیده می‌شود، نه تنها معضل اطلاعات منقضی‌شده را برطرف می‌سازد، بلکه با فراهم آوردن امکان ارجاع‌دهی دقیق به منابع و مراجع معتبر^{۱۳}، شفافیت و اعتماد کاربر به سیستم را به شکل چشمگیری افزایش می‌دهد [۱۰].

۳-۱ چالش‌های معماری استاندارد RAG در فضای وب

در ادبیات موضوع فعلی، معماری «تولید افزوده با بازیابی» یا رگ^{۱۴} به عنوان راهکاری استاندارد و اثبات‌شده برای تزریق دانش خارجی و غیرپارامتریک به مدل‌های زبانی شناخته می‌شود [۱۱، ۱۲]. با این حال، خط لوله‌ی RAG^{۱۵} سنتی عمدتاً برای کار بر روی اسناد ثابت، ساختاریافته و آفلاین (مانند پایگاه داده‌ای از فایل‌های سازمانی) طراحی شده است و در مواجهه با فضای وب با چالش‌های فنی و معنایی اساسی روبرو است.

فضای وب، محیطی به شدت پویا، پرنویز، ناهمگن و غیرقابل پیش‌بینی است. در RAG سنتی، اسناد پیش از استفاده، طی یک فرآیند آفلاین پردازش، پاک‌سازی و قطعه‌بندی^{۱۶} شده و در یک پایگاه داده برداری^{۱۷} ذخیره می‌گردند. اما در فرآیند وب‌گردی در لحظه^{۱۸}، زمان کافی برای این پیش‌پردازش عمیق وجود ندارد. سیستم باید بتواند در کسری از ثانیه، محتوای صفحات وب بازیابی‌شده را که حاوی حجم زیادی از تبلیغات، کدهای مخرب، ساختارهای پیچیده HTML و نویزهای بصری هستند، دریافت و پالایش کند [۱۳].

همچنین در RAG سنتی، معمولاً پرسش اولیه کاربر مستقیماً برای جستجوی معنایی استفاده می‌شود؛ اما در وب، پرسش اولیه کاربر ممکن است مبهم یا چندوجهی باشد و برای یافتن پاسخ جامع، نیازمند تجزیه به چندین پرس و جوی فرعی و مستقل^{۱۹} باشد؛ قابلیت‌هایی که در سیستم‌های جستجوی معنایی پایه تعبیه نشده و نیازمند یک ماژول تصمیم‌گیر (عامل هوشمند) برای مدیریت بسط پرس و جوهاست [۱۴].

¹²Web Grounding

¹³Citations

¹⁴Retrieval-Augmented Generation (RAG)

¹⁵Pipeline

¹⁶Chunking

¹⁷Vector Database

¹⁸Real-time Web Browsing

¹⁹Multi-query Generation

۴-۱ اهداف پژوهش

هدف اصلی این پژوهش، طراحی، توسعه و ارزیابی یک موتور جستجوی هوشمند و گفتگومحور است که توانایی استخراج بلادرنگ اطلاعات از وب و ترکیب آن با قدرت استدلال مدل‌های زبانی را داشته باشد. در راستای تحقق این هدف کلان، اهداف خرد زیر دنبال می‌شوند:

- مطالعه، بررسی و تحلیل معماری سامانه‌های نوین جستجوی هوشمند مبتنی بر مدل‌های زبانی بزرگ.
- طراحی یک سامانه ترکیبی دوحالته با قابلیت تشخیص خودکار و سوئیچ بین «پاسخ‌گویی عادی (مبتنی بر دانش پارامتریک)» و «پاسخ‌گویی مبتنی بر بازیابی از وب».
- پیاده‌سازی مکانیزم آگاهی از بافتار^{۲۰} با استفاده از تزریق تاریخچه گفتگوها جهت تولید پاسخ‌های پیوسته، منطقی و چندنوبتی^{۲۱}.
- بررسی و پیاده‌سازی مکانیزم‌های پیشرفته‌ی بازمرده‌ی و بازرتبه‌بندی پرس‌وجوها و متون استخراج‌شده از وب برای یافتن مرتبط‌ترین قطعات متنی و کاهش نویز.
- طراحی یک چارچوب ارزیابی جامع برای سنجش عملکرد و کیفیت خروجی سامانه پیشنهادی روی مجموعه‌ای از پرسش‌های چالشی، مبهم و نیازمند اطلاعات لحظه‌ای.

۵-۱ پرسش‌های پژوهش

این پژوهش در پی یافتن پاسخ علمی، مستدل و قابل اندازه‌گیری برای پرسش‌های اساسی زیر است:

- آیا ادغام جستجوی وب بلادرنگ با مدل‌های زبانی بزرگ، موجب کاهش معنادار پدیده توهم و بهبود دقت فاکچوال^{۲۲} در پاسخ‌گویی به پرسش‌های دانش‌محور می‌شود؟
- آیا به‌کارگیری تکنیک‌ها و مدل‌های بازرتبه‌بندی^{۲۳} بر روی نتایج خام استخراج‌شده از صفحات وب، کیفیت، انسجام و ارتباط معنایی پاسخ نهایی ارائه‌شده به کاربر را ارتقا می‌دهد؟
- در یک محیط تعاملی و چندنوبتی، تزریق تاریخچه گفتگوها به ماژول تولید پرس‌وجو، تا چه میزان در درک بهتر نیت پنهان کاربر و تولید کلیدواژه‌های جستجوی دقیق‌تر مؤثر است؟

²⁰Context-awareness

²¹Multi-turn

²²Factual Accuracy

²³Reranker

۱-۶ نوآوری و سهم کار

سهم اصلی و نوآوری این پژوهش، فراتر رفتن از یک رابط برنامه‌نویسی^{۲۴} ساده و توسعه یک سیستم یکپارچه، ماژولار و عامل‌گونه^{۲۵} است که به صورت خودمختار توانایی مدیریت جریان اطلاعات را داراست. دستاوردهای کلیدی و نوآوری‌های این پایان‌نامه عبارتند از:

- طراحی و پیاده‌سازی یک سامانه‌ی پردازشی هوشمند با قابلیت تشخیص خودکار نیاز به جستجوی خارجی (کاهش سربار سیستم با طراحی دوحالت).
- توسعه یک ماژول تخصصی برای تولید و بسط پرس‌وجو^{۲۶}، که قادر است با تحلیل ترکیب سؤال فعلی کاربر و بافتار تاریخیچه چت، چندین پرس‌وجوی مستقل و بهینه برای موتور جستجوی وب تولید نماید.
- توسعه الگوریتمی برای تجمیع اطلاعات پراکنده از منابع مختلف وب، پالایش نویزهای HTML، و تولید یک پاسخ نهایی جامع همراه با سیستم ارجاع‌دهی درون‌متنی^{۲۷}.
- طراحی و اجرای یک خط لوله ارزیابی علمی برای مقایسه عملکرد سیستم در حالت پایه^{۲۸} در برابر حالت مجهز به مدل‌های بازرتبه‌بندی.

۱-۷ روش کلی انجام کار

روند کلی انجام این پژوهش مبتنی بر توسعه یک خط لوله (Pipeline) پردازشی چندمرحله‌ای و هوشمند است. در این فرآیند، ابتدا درخواست کاربر دریافت شده و همراه با تاریخچه گفتگوهای پیشین به ماژول تحلیل نیت ارسال می‌گردد. سیستم با بهره‌گیری از یک مدل زبانی پایه، نیاز اطلاعاتی کاربر را تحلیل کرده و در صورت تشخیص نیاز به داده‌های به‌روز، آن را به چند پرس‌وجوی (Query) بهینه و مجزا می‌شکند. در گام بعدی، این پرس‌وجوها از طریق رابط موتور جستجو به شبکه وب ارسال شده و صفحات مرتبط شناسایی و بارگیری (Scrape) می‌شوند. محتوای متنی این صفحات استخراج شده و به قطعات کوچکتر

²⁴API

²⁵Agentic

²⁶Query Expansion

²⁷In-text Citation

²⁸Basic Web Retrieval

تقسیم می‌گردد. سپس به کمک یک مدل بازرتبه‌بند مبتنی بر شبکه‌های عصبی متقاطع^{۲۹} [۱۵]، این قطعات متنی بر اساس بیشترین میزان هم‌پوشانی معنایی با نیاز کاربر، فیلتر و مرتب‌سازی می‌شوند.

در نهایت، متونِ پالایش‌شده‌ی برتر به عنوان «بافتارِ دانش» به دستورالعمل^{۳۰} مدل زبانی بزرگ تزریق می‌شوند تا مدل بتواند پاسخی نهایی، دقیق، مستدل و ارجاع‌دار تولید کرده و به کاربر نمایش دهد. در فاز پایانی پژوهش نیز، کیفیت خروجی‌های این معماری با استفاده از متریک‌های ارزیابی کیفی رایج در حوزه پردازش زبان طبیعی سنجیده و تحلیل خواهند شد.

۸-۱ ساختار پایان‌نامه

[این بخش پس از نهایی شدن نگارش فصول بعدی پایان‌نامه تکمیل خواهد شد. در این قسمت طی یک یا دو پاراگراف، محتوای فصول دوم (مروری بر ادبیات موضوع)، سوم (روش‌شناسی و معماری سیستم پیشنهادی)، چهارم (پیاده‌سازی، آزمایش‌ها و ارزیابی نتایج) و پنجم (نتیجه‌گیری و کارهای آتی) به اختصار شرح داده خواهد شد.]

²⁹Cross-encoder Reranker

³⁰Prompt

فصل ۲

مفاهیم پایه و مبانی نظری

هدف از این فصل، ارائه پایه‌های علمی، نظری و فنی مفاهیمی است که در طراحی و پیاده‌سازی سامانه‌های هوشمند مبتنی بر مدل‌های زبانی^۱ و جستجوی وب نقش اساسی ایفا می‌کنند. پیش از ورود به معماری دقیق سیستم پیشنهادی در فصول آتی، درک عمیق مکانیزم‌های سنتی بازیابی اطلاعات^۲، بررسی دقیق محدودیت‌های مدل‌های زبانی، معماری نوین تولید افزوده شده با بازیابی^۳ (RAG) و چالش‌های پیچیده تعامل با محیط پویای وب الزامی است. این فصل به عنوان پیش‌نیازی مستحکم برای درک منطق، الگوریتم‌ها و نوآوری‌های مطرح شده در ادامه پایان‌نامه عمل می‌کند.

۲-۱ موتورهای جستجوی سنتی

پیش از ظهور مدل‌های زبانی هوشمند و سامانه‌های تولیدگر^۴، دسترسی به اطلاعات در وب عمدتاً از طریق موتورهای جستجوی سنتی^۵ انجام می‌پذیرفت. معماری موتورهای جستجوی وب معمولاً شامل خزنده‌های توزیع شده، نمایه‌ساز، ساخت نمایه معکوس و جزء جستجوگر است [۱۶]. کارکرد این موتورها بر چهار پایه اصلی استوار است:

۱. خزش^۶: (Crawling) ربات‌های نرم‌افزاری^۷ صفحات وب را به صورت گراف‌پیمایی^۸ پیمایش

^۱Language Models

^۲Information Retrieval

^۳Retrieval-Augmented Generation

^۴Generative Systems

^۵Traditional Search Engines

^۶Crawling

^۷Software Bots

^۸Graph Traversal

کرده و محتوای آن‌ها را برای پردازش‌های بعدی جمع‌آوری می‌کنند.

۲. نمایه‌سازی^۹: (Indexing) محتوای جمع‌آوری شده پس از پیش‌پردازش متنی^{۱۰} (نظیر حذف

کلمات توقف^{۱۱} و ریشه‌یابی^{۱۲}) در ساختارهای داده‌ای بهینه‌سازی شده مانند نمایه‌ی معکوس^{۱۳} (In-

verted Index) ذخیره می‌شود تا جستجو با پیچیدگی زمانی حداقل و سرعت بالا انجام پذیرد [۲].

۳. بازیابی و رتبه‌بندی^{۱۴} (Retrieval & Ranking) هنگامی که کاربر پرس‌وجویی^{۱۵} ارسال

می‌کند، سیستم با استفاده از الگوریتم‌های آماری نظیر $TF - IDF$ [۱۷] یا نسخه‌های پیشرفته‌تر

مبتنی بر احتمالات نظیر BM_{25} [۳]، مرتبط‌ترین اسناد را بازیابی می‌کند. سپس نتایج بر اساس

فاکتورهای چون ارتباط معنایی کلیدواژه‌ها و اعتبار مبتنی بر ساختار لینک‌ها^{۱۶} (مانند الگوریتم

$PageRank$ [۱۸]) مرتب می‌شوند.

۴. نمایش نتایج: خروجی فرآیند به صورت لیستی از پیوندها (Links) و خلاصه‌های کوتاه^{۱۷}

(Snippets) به کاربر ارائه می‌شود.

اگرچه این موتورها در یافتن صفحات وب بسیار مقیاس‌پذیر^{۱۸} و کارآمد هستند، اما عمدتاً وظیفه‌ی

یافتن و رتبه‌بندی اسناد را برعهده دارند و معمولاً پاسخ نهایی را به صورت مستقیم تولید نمی‌کنند. بنابراین

برای پرسش‌های تحلیلی که نیازمند ترکیب اطلاعات از چندین منبع متمایز و استخراج منطقی^{۱۹} هستند،

به تنهایی کافی نیستند [۱۹]. این محدودیت بنیادین، نقطه شروع گذار پژوهشگران به سمت سامانه‌های

هوشمندتر مبتنی بر هوش مصنوعی بود.

⁹Indexing

¹⁰Text Preprocessing

¹¹Stop Words

¹²Stemming

¹³Inverted Index

¹⁴Retrieval & Ranking

¹⁵Query

¹⁶Link-based Authority

¹⁷Snippets

¹⁸Scalable

¹⁹Logical Inference

۲-۲ مدل‌های زبانی بزرگ^{۲۰} (LLMs) و پاسخ‌گویی محاوره‌ای

مدل‌های زبانی بزرگ شبکه‌های عصبی عمیقی^{۲۱} (غالباً مبتنی بر معماری ترانسفورمر^{۲۲} و مکانیزم توجه^{۲۳} [۲۰]) هستند که روی حجم عظیمی از داده‌های متنی آموزش دیده‌اند. این مدل‌ها قادرند با پیش‌بینی توکن بعدی^{۲۴} با استفاده از احتمالات ریاضی، متن‌هایی بسیار روان، منسجم و انسان‌گونه تولید کنند. در مقیاس بزرگ، همین هدف آموزشی باعث ظهور توانایی‌هایی مانند یادگیری با چند نمونه^{۲۵} می‌شود [۱]. با این وجود، استفاده مستقیم از این مدل‌ها به عنوان موتور پاسخ‌گویی دارای چالش‌های جدی زیر است:

- **توهم^{۲۶}: (Hallucination)** مدل‌های زبانی گاهی پاسخ‌هایی تولید می‌کنند که از نظر قواعد گرامری کاملاً صحیح به نظر می‌رسند، اما از نظر حقایق بیرونی کاملاً ساختگی و غلط هستند. این توهم می‌تواند به شکل جعل واقعیت یا تقلید از باورهای نادرست انسانی بروز کند [۵، ۶].
- **دانش ایستا و قدیمی^{۲۷} (Static Knowledge):** دانش جاسازی‌شده در وزن‌های مدل محدود به داده‌هایی است که تا زمان آموزش^{۲۸} دیده‌است. بنابراین مدل بدون جستجوی زنده، در مورد اخبار یا رویدادهای جدید گرایش به ارائه پاسخ‌های منسوخ دارد [۴].
- **نبود ارجاع‌پذیری^{۲۹} of (Lack Attribution):** مدل به صورت ذاتی نمی‌تواند نشان دهد که پاسخ تولید شده را از کدام منبع یاد گرفته است، که این امر اعتمادپذیری^{۳۰} سیستم را در کاربردهای حساس (پزشکی، حقوقی و آکادمیک) به شدت کاهش می‌دهد.
- **محدودیت پنجره بافت^{۳۱} (Context Window):** مدل‌ها محدودیت حافظه در پردازش توکن‌ها دارند. افزون بر این، پدیده‌ای به نام «گم‌شدن در میانه»^{۳۲} نشان می‌دهد که حتی با افزایش طول پنجره بافت، مدل‌ها لزوماً از تمام اطلاعات به‌طور یکنواخت استفاده نمی‌کنند و تمرکز آن‌ها بیشتر بر ابتدا و انتهای متن است [۲۱].

²⁰Large Language Models

²¹Deep Neural Networks

²²Transformer Architecture

²³Attention Mechanism

²⁴Next Token Prediction

²⁵Few-shot Learning

²⁶Hallucination

²⁷Static Knowledge

²⁸Knowledge Cut-off

²⁹Lack of Attribution

³⁰Reliability

³¹Context Window

³²Lost in the Middle

۳-۲ تولید افزوده شده با بازیابی^{۳۳} (RAG)

برای غلبه بر چالش‌های ذاتی مدل‌های زبانی، معماری تولید افزوده شده با بازیابی معرفی شد [۱۱]. این رویکرد حافظه پارامتریک (وزن‌های مدل) را با دانش ماژولار و غیرپارامتریک (اسناد خارجی) ترکیب می‌کند [۲۲]. معماری کلاسیک RAG از دو بخش اصلی تشکیل شده است:

۱. بازیاب^{۳۴}: (Retriever) ابتدا پرسش کاربر با استفاده از یک مدل جاسازی^{۳۵} به یک بردار ریاضی چگال^{۳۶} در فضای ابعاد بالا تبدیل می‌شود. سپس در یک پایگاه داده برداری^{۳۷}، جستجوی همسایگی (مانند *Cosine Similarity* یا روش‌های تقریبی *ANN* [۲۳]) انجام شده و $Top-k$ سند مرتبط از نظر معنایی بازیابی می‌شود [۲۴].

۲. تولیدکننده^{۳۸}: (Generator) اسناد بازیابی شده به عنوان «بافت خارجی^{۳۹}» به همراه پرسش اصلی کاربر، در قالب یک پرامپت ساختاریافته به LLM تزریق می‌شوند. مدل زبانی اکنون موظف است پاسخ را منحصراً بر اساس این اطلاعات ارائه شده تولید کند.

این رویکرد می‌تواند پدیده توهم را به شکل قابل توجهی کاهش داده و امکان ارجاع‌پذیری را فراهم کند. با این حال، کیفیت پاسخ نهایی مستقیماً به کیفیت بازیابی و میزان تبعیت مدل از شواهد ارائه شده بستگی دارد.

۴-۲ تفاوت RAG کلاسیک با RAG مبتنی بر وب (چالش‌های اساسی)

معماری RAG در ابتدا روی مجموعه‌های متنی ایستا و ساختاریافته (مانند مقالات ویکی‌پدیا) آزمایش شد. اما پیاده‌سازی این الگو بر روی گستره نامتناهی «وب» چالش‌های فنی متفاوتی را به همراه دارد:

- پویایی و مقیاس‌پذیری^{۴۰}: محیط وب مجموعه‌ای عظیم و دائماً در حال تغییر است. بنابراین ساخت و نگهداری یک نمایه برداری کامل و محلی از کل وب برای سامانه‌های محلی عملی نیست.

³³Retrieval-Augmented Generation

³⁴Retriever

³⁵Embedding Model

³⁶Dense Vector

³⁷Vector Database

³⁸Generator

³⁹External Context

⁴⁰Dynamism and Scalability

- ناهمگنی، نویز و اسپم^{۴۱}: صفحات وب دارای ساختارهای متغیر، تبلیغات، قالب‌های تکراری و اطلاعات نامعتبر هستند. استخراج متن خالص و حذف نویزها^{۴۲} [۱۳] در کنار مقابله با محتوای فریبنده و اسپم [۲۵] یک ضرورت پیچیده در این محیط است.
- نیاز به تفکیک پرسش‌ها^{۴۳} (Query Decomposition): در محیط وب، پاسخ به یک سؤال تحلیلی معمولاً در یک سند واحد یافت نمی‌شود [۲۶]. سیستم هوشمند باید بتواند یک سؤال پیچیده را به چند زیرسؤال شکسته و جستجوهای متعددی^{۴۴} را انجام دهد.

۵-۲ سامانه‌های مبتنی بر جستجوی وب (Search-Augmented LLMs) و ابزارهای API

به منظور مقابله با چالش‌های یاد شده، سامانه‌های پیشرفته امروزی مدل‌های زبانی را مستقیماً به ابزارهای خارجی نظیر جستجوی وب (API) متصل می‌کنند [۲۷، ۲۸]. مراحل پردازشی در این سامانه‌ها عموماً به شرح زیر است:

۱. بازنویسی پرس‌وجو^{۴۵} (Query Reformulation): از آنجا که پرسش طبیعی کاربر لزوماً بهترین عبارت برای موتور جستجو نیست، مدل زبانی آن را به مجموعه‌ای از کلیدواژه‌های بهینه تبدیل می‌کند [۲۹].
۲. انتخاب منابع^{۴۶}: نتایج خام دریافتی از API ارزیابی شده و سایت‌های نامعتبر یا نتایج نامربوط فیلتر می‌شوند.
۳. استدلال چندمرحله‌ای و بازیابی فعال^{۴۷}: مدل در چرخه‌ای از فکر و عمل [۳۰] متون را بررسی می‌کند. در صورت نقص اطلاعات، در طول فرآیند تولید پاسخ، پرسش‌های جدیدی تولید کرده و فاز جستجو را تکرار می‌کند [۳۱].
۴. تولید ارجاعات^{۴۸}: در گام نهایی، مدل زبانی در حین تولید پاسخ، با استفاده از شناسه‌های یکتا مشخص می‌کند که هر ادعا از کدام پیوند استخراج شده است.

⁴¹Heterogeneity and Spam

⁴²Boilerplate Removal

⁴³Query Decomposition

⁴⁴Multi-hop Retrieval

⁴⁵Query Reformulation

⁴⁶Source Selection

⁴⁷Active Retrieval

⁴⁸Citation Generation

۶-۲ نقش تاریخچه گفتگو در پاسخ‌گویی محاوره‌ای

یکی از ارکان اساسی سامانه‌های دستیار هوشمند مدرن، حفظ حالت محاوره‌ای^{۴۹} است. در یک گفتگوی چندنوبتی، کاربران تمایل دارند از ضمائر اشاره استفاده کنند یا سؤالات خود را با فرض آگاهی سیستم از مکالمات قبلی مطرح نمایند.

بدون مدیریت دقیق تاریخچه، سؤال فعلی کاربر به تنهایی فاقد معنای کامل بوده و موتور بازیابی را گمراه می‌کند. در این سامانه‌ها، بازنویسی پرسش وابسته به گفتگو^{۵۰} انجام می‌شود تا پرسش فعلی با استفاده از بافتار مکالمات پیشین به یک پرسش مستقل و شفاف برای موتور جستجو تبدیل گردد [۳۲].

۷-۲ بازرتبه‌بندی^{۵۱} یا Re-ranking

موتورهای جستجو و API‌های وب به دلیل نیاز به پاسخ‌گویی در مقیاس میلی‌ثانیه، معمولاً از مدل‌های رمزگذار دوگانه^{۵۲} [۱۵] یا تطابق دقیق کلمات استفاده می‌کنند. در این روش‌ها، پرسش و سند به صورت مستقل پردازش می‌شوند. خروجی اولیه این موتورها ممکن است صدها سند مرتبط را بازگرداند که از نظر معنایی دقیقاً پاسخگوی سؤال پیچیده کاربر نیستند.

برای حل این مشکل از معماری دو مرحله‌ای استفاده می‌شود. پس از بازیابی اولیه و سریع اسناد، مفهوم رتبه‌بندی مجدد با استفاده از مدل‌های رمزگذار متقاطع^{۵۳} مطرح می‌گردد [۳۳]. این مدل‌های یادگیری عمیق، پرسش کاربر و متن سند را به صورت همزمان دریافت کرده و ارتباط را در سطح کلمه-به-کلمه محاسبه می‌کنند. در سامانه‌های عملی، ترکیب بازیابی سریع اولیه با بازرتبه‌بندی دقیق، توازن ایده‌آل میان فراخوانی، دقت و هزینه محاسباتی ایجاد می‌کند [۳۴] تا تنها بهترین اسناد به LLM ارسال گردند.

۸-۲ معیارهای ارزیابی سامانه‌ها^{۵۴}

برای سنجش علمی و کمی عملکرد سامانه‌های RAG مبتنی بر جستجو، ارزیابی باید به صورت تفکیک‌شده در دو سطح «موتور بازیابی» و «موتور تولید پاسخ» انجام شود [۳۵]. مهم‌ترین معیارهای استاندارد ارزیابی

⁴⁹Conversational State

⁵⁰Conversational Query Rewriting

⁵¹Re-ranking

⁵²Bi-Encoders

⁵³Cross-Encoders

⁵⁴System Evaluation Metrics

عبارتند از:

- **دقت^{۵۵} و فراخوانی^{۵۶}:** معیارهای کلاسیک ارزیابی بازیابی. دقت نشان می‌دهد چه کسری از اسناد بازیابی شده مرتبط بوده‌اند و فراخوانی نشان‌دهنده کسر اسناد مرتبط بازیابی شده نسبت به کل اسناد مرتبط موجود است.
 - **نرخ برخورد^{۵۷} و میانگین رتبه متقابل^{۵۸} (MRR):** بررسی اینکه آیا در نتایج اولیه حداقل یک سند حاوی پاسخ طلایی وجود داشته است و در چه رتبه‌ای قرار دارد.
 - **وفاداری^{۵۹}:** بررسی اینکه آیا محتوای تولید شده، مستقیماً از اسناد ارائه‌شده قابل استنتاج است یا مدل دچار توهم شده است.
 - **صحت ارجاع^{۶۰}:** معیاری دقیق‌تر برای اطمینان از اینکه ارجاع و پیوند ثبت شده در کنار هر خط از پاسخ، دقیقاً همان ادعای متنی را پشتیبانی می‌کند [۱۰].
 - **سودمندی^{۶۱}:** بررسی میزان تطابق پاسخ نهایی با نیت اصلی کاربر و رفع نیاز اطلاعاتی وی.
- این معیارهای کمی و کیفی پایه‌های نظری لازم برای طراحی آزمایش‌ها، پیکربندی بهینه هایپرپارامترها^{۶۲} و اثبات کارایی سامانه‌ی پیشنهادی در فصول آتی را فراهم می‌آورند.

⁵⁵Precision

⁵⁶Recall

⁵⁷Hit Rate

⁵⁸Mean Reciprocal Rank

⁵⁹Faithfulness

⁶⁰Citation Accuracy

⁶¹Answer Relevance

⁶²Hyperparameters

فصل ۳

کارهای پیشین و تحلیل سامانه‌های موجود

در فصل سوم، پیشینه‌ی تحقیق و کارهای انجام‌شده در حوزه‌ی سامانه‌های پاسخ‌گویی هوشمند و جست‌وجوی مبتنی بر مدل‌های زبانی به تفصیل مورد بررسی قرار می‌گیرد. مبنای نظری این سامانه‌ها را می‌توان در معماری تولید افزوده با بازیابی^۱ مشاهده کرد؛ چارچوبی که دانش پارامتری مدل زبانی را با حافظه‌ی غیرپارامتری مبتنی بر اسناد خارجی ترکیب می‌کند و برای پرسش‌های دانش‌محور عملکرد بهتری نسبت به مدل‌های صرفاً مولد نشان می‌دهد [۱۱]. در ادبیات جدید، RAG به‌عنوان یکی از مهم‌ترین راهکارها برای کاهش نرخ توهم^۲، رفع مشکل دانش منسوخ و افزایش قابلیت ردیابی پاسخ‌های مدل‌های زبانی معرفی شده است [۱۲].

هدف از این فصل، بررسی جامع و تحلیلی سامانه‌های پیشگام در این حوزه است. در این راستا، ابتدا سه مورد از اثرگذارترین سیستم‌های فعلی یعنی پرپلکسیتی^۳، نمای کلی هوش مصنوعی گوگل^۴ و مایکروسافت کوپایلت^۵ از منظر تاریخچه، هویت و معماری فنی تحلیل می‌شوند. در نهایت، با ارائه‌ی یک تحلیل تطبیقی از این سامانه‌ها، شکاف‌های پژوهشی موجود شناسایی شده و ضرورت پیاده‌سازی لایه‌ی بازرتبه‌بندی^۶ در سامانه‌ی پیشنهادی این پژوهش تبیین می‌گردد.

^۱Retrieval-Augmented Generation (RAG)

^۲Hallucination

^۳Perplexity AI

^۴Google AI Overviews

^۵Microsoft Bing Copilot

^۶Reranking

۳-۱ تحلیل سامانه‌ی پرپلکسیستی (پارادایم موتور پاسخ‌دهی)

سامانه‌ی پرپلکسیستی در سال ۲۰۲۲ با هدف بازتعریف مفهوم جست‌وجو تأسیس شد. فلسفه‌ی بنیادین این سیستم، گذار از مفهوم سنتی «موتور جست‌وجو»^۷ به «موتور پاسخ‌دهی»^۸ است. در حالی که موتورهای سنتی کاربر را به سمت منابع و پیوندها هدایت می‌کنند، پرپلکسیستی با اتخاذ رویکرد **سنتز اطلاعات**، یک پاسخ نهایی بر پایه‌ی اطلاعات بلادرنگ تولید کرده و منابع را صرفاً به‌عنوان ابزاری برای تأیید صحت^۹ و شفافیت ارائه می‌دهد [۷].

پیش‌زمینه‌ی این رویکرد پیش‌تر در پژوهش WebGPT نیز مطرح شده بود که نشان داد اتصال مدل زبانی به محیط مرور وب و الزام آن به جمع‌آوری منابع در حین پاسخ‌گویی، می‌تواند شفافیت و قابلیت راستی‌آزمایی پاسخ‌ها را به شکل چشمگیری افزایش دهد [۲۷]. با توجه به مستندات عمومی درباره‌ی پرپلکسیستی و نیز الگوهای رایج در سامانه‌های RAG پیشرفته، می‌توان معماری آن را به‌صورت یک خط لوله‌ی چندمرحله‌ای به شرح زیر تحلیل کرد:

- **تحلیل نیت پرسش**^{۱۰}: تحلیل معنایی پرسش توسط یک مدل زبانی بزرگ^{۱۱} برای تشخیص نیت کاربر.
- **بسط عاملی پرسش**^{۱۲}: تبدیل پرسش‌های پیچیده به چندین زیرپرسش^{۱۳} جهت حداکثرسازی پوشش اطلاعاتی.
- **بازیابی ترکیبی**^{۱۴}: استفاده‌ی هم‌زمان از استراتژی‌های بازیابی. بازیابی **تُنک**^{۱۵} (مانند BM25) در تطبیق واژگان دقیق و نام‌ها بسیار قدرتمند است [۳]، در حالی که بازیابی **چگال**^{۱۶} شباهت معنایی و بازنویسی‌های مفهومی را بهتر درک می‌کند [۲۴]. ترکیب این دو، نرخ بازیابی (Recall) را در مواجهه با وب به حداکثر می‌رساند.
- **بازرتبه‌بندی چندلایه**^{۱۷}: عبور نتایج از فیلترهایی نظیر بررسی قابلیت استخراج از HTML، استفاده از مدل‌های رمزگذار متقاطع^{۱۸} و اولویت‌دهی به اعتبار منابع.

⁷Search Engine

⁸Answer Engine

⁹Verification

¹⁰Query Intent Parsing

¹¹LLM

¹²Agentic Query Expansion

¹³Sub-queries

¹⁴Hybrid Retrieval

¹⁵Sparse Retrieval

¹⁶Dense Retrieval

¹⁷Multi-Tier Reranking

¹⁸Cross-Encoder

- تولید مستند^{۱۹}: تولید پاسخ توسط مدل زبانی با الزام به درج ارجاعات به صورت شماره گذاری شده در متن.

۲-۳ تحلیل سامانه‌ی گوگل (معماری SGE و ادغام گراف دانش)

سامانه‌ی نمای کلی هوش مصنوعی گوگل (AI Overviews)، به عنوان لایه‌ای مولد بر فراز زیرساخت جست‌وجوی این شرکت معرفی شده است که قابلیت‌های مدل‌های خانواده‌ی جِمینای^{۲۰}، از جمله استدلال چندمرحله‌ای و پردازش چندوجهی را با عظیم‌ترین نمایه‌ی وب جهان ترکیب می‌کند [۹].

یکی از برتری‌های ساختاری گوگل نسبت به سامانه‌های مستقل، استفاده از گراف دانش^{۲۱} است. این گراف که موجودیت‌های جهان واقعی و روابط میان آن‌ها را مدل می‌کند، نقش حیاتی در برطرف کردن ابهامات معنایی^{۲۲} و پیشنهاد مسیرهای اکتشافی دارد [۳۶]. علاوه بر این، گوگل در مستندات رسمی خود بیان می‌کند که این سامانه ممکن است از تکنیک بسطِ انشعابی^{۲۳} استفاده کند؛ در این تکنیک، پرسش کاربر به چند جست‌وجوی مرتبط در زیرموضوع‌ها و منابع داده‌ای مختلف گسترش می‌یابد تا پاسخ نهایی بر شواهد گسترده‌تری متکی باشد [۳۷].

برای ادغام نتایج حاصل از این بازیابی‌های موازی، یکی از روش‌های شناخته‌شده در ادبیات بازیابی اطلاعات، الگوریتم ادغام رتبه‌ی متقابل^{۲۴} است [۳۸]. امتیاز هر سند در این الگوریتم به صورت زیر محاسبه می‌شود:

$$\text{Score}(d) = \sum_{q \in \text{Queries}} \frac{1}{k + \text{rank}(q, d)} \quad (۱-۳)$$

در این رابطه، k یک مقدار ثابت (معمولاً برابر با ۶۰) است. این روش به هر سند بر اساس رتبه‌ی آن امتیازی معکوس اختصاص داده و اسنادی را که در جست‌وجوهای مختلف رتبه‌ی بالایی کسب کرده‌اند، تقویت می‌کند.

¹⁹Grounded Generation

²⁰Gemini

²¹Knowledge Graph

²²Disambiguation

²³Query Fan-out

²⁴Reciprocal Rank Fusion (RRF)

۳-۳ تحلیل مایکروسافت کوپایلت (معماری پرومیتوس)

سامانه‌ی مایکروسافت کوپایلت، نتیجه‌ی ادغام نمایه‌ی موتور جست‌وجوی بینگ با مدل‌های خانواده‌ی GPT شرکت OpenAI است. مایکروسافت لایه‌ای اختصاصی به نام پرومیتوس^{۲۵} را به‌عنوان میانجی توسعه داده است. در این معماری، بخشی به نام هماهنگ‌کننده^{۲۶} پرسش‌های داخلی مرتبط را به‌صورت تکراری تولید کرده و فرآیندی به نام اتصال^{۲۷} را شکل می‌دهد که طی آن مدل بر داده‌های به‌روز بینگ استدلال می‌کند [۸].

از منظر پژوهشی، این معماری را می‌توان مبتنی بر حلقه‌ی استدلال-بازیابی دانست که با کار پژوهشگرانی نظیر تریودی و همکاران (IRCoT) نیز پشتیبانی می‌شود. این الگو نشان می‌دهد که در پرسش‌های پیچیده و چندمرحله‌ای، بازیابی یک‌باره کافی نیست؛ بلکه مدل باید پس از هر گام استدلال، بر اساس نیاز اطلاعاتی جدید جست‌وجوی تازه‌ای انجام دهد تا نقص‌های اطلاعاتی برطرف گردد [۱۴].

۴-۳ تحلیل تطبیقی سامانه‌های پیشرو

برای درک بهتر تفاوت‌ها و شباهت‌های بنیادین میان سامانه‌های بررسی‌شده، ویژگی‌های فنی و معماری احتمالی آن‌ها بر اساس مستندات عمومی در جدول ۳-۱ خلاصه‌سازی شده است. این ماتریس نشان می‌دهد که چگونه تفاوت در فلسفه‌ی طراحی، به استراتژی‌های متفاوت در توسعه‌ی RAG تجاری منجر شده است.

۵-۳ تحلیل تئوریک بازرتبه‌بندی و تبیین شکاف پژوهشی

در سامانه‌های RAG، کیفیت پاسخ نهایی تنها تابع توانمندی مدل زبانی نیست، بلکه به‌شدت به کیفیت شواهد بازیابی‌شده وابسته است. اگر مرحله‌ی بازیابی، اسناد نامرتب یا متناقض را وارد بافتار کند، مدل زبانی ممکن است پاسخی روان اما نادرست تولید کند. برای کنترل این چالش، فرآیند بازیابی اطلاعات معمولاً در دو لایه انجام می‌شود:

- مرحله‌ی اول (رمزگذارهای دوگانه)^{۲۸}: پرسش و اسناد مستقل از هم به بردار تبدیل شده و شباهت

²⁵Prometheus

²⁶Bing Orchestrator

²⁷Grounding

²⁸Bi-Encoders

جدول ۳-۱: ماتریس فنی و تحلیل تطبیقی معماری سامانه‌های پاسخ‌گویی هوشمند

ویژگی فنی	پرپلکسیتی	گوگل	مایکروسافت
فلسفه طراحی	موتور پاسخ‌دهی	جست‌وجوی مولد مبتنی بر نمایه‌ی Search	دستیار مبتنی بر جست‌وجو و بهره‌وری معماری پرومیتوس + Orchestrator
شواهد معماری	پژوهش محور پاسخ سنتز شده همراه با ارجاع دقیق	ترکیب Gemini و سیستم‌های سنتی جست‌وجو	تولید پرسش‌های داخلی تکرار شونده
استراتژی احتمالی بازیابی	RAG وب‌محور (احتمالاً ترکیبی)	تکنیک Fan-out (تأیید شده در مستندات)	اتصال متوالی روی داده‌های بینگ
ادغام و کنترل شواهد	قابل تحلیل با الگوی بازرتبه‌بندی	ادغام نتایج انشعابی (الگوهای مشابه RRF)	ارجاعات درون‌متنی تعاملی
نحوه‌ی ارجاع‌دهی	ارجاعات دقیق و شماره‌گذاری شده	لینک‌های پشتیبان متنی (کارت‌های منبع)	

آن‌ها ارزیابی می‌شود. مزیت اصلی این لایه سرعت بسیار بالا است (مانند معماری Sentence-BERT که زمان جست‌وجو را به شدت کاهش می‌دهد [۱۵])، اما دقت پایینی در تشخیص روابط پیچیده‌ی معنایی دارد.

- **مرحله‌ی دوم (رمزگذارهای متقاطع)**^{۲۹}: در این لایه که به‌عنوان بازرتبه‌بندی شناخته می‌شود، پرسش و سند هم‌زمان وارد شبکه‌ی ترانسفورمر می‌شوند تا تعاملات معنایی آن‌ها توکن‌به‌توکن محاسبه گردد. پژوهش‌ها نشان می‌دهد استفاده از مدل‌هایی نظیر BERT به عنوان بازرتبه‌بند می‌تواند معیارهای رتبه‌بندی را به شکل قابل‌توجهی ارتقا دهد [۳۳]. همچنین مدل‌های تعامل دیر هنگام^{۳۰} نظیر ColBERT نیز به‌عنوان راهکار میانی برای ایجاد تعادل بین سرعت و دقت پیشنهاد شده‌اند [۳۹].

۳-۵-۱ RAG تجاری در برابر RAG آکادمیک و شکاف‌های موجود

سامانه‌های تجاری بررسی شده در این فصل، نمونه‌هایی از RAG عملیاتی در مقیاس وب هستند. تفاوت اساسی آن‌ها با نمونه‌های دانشگاهی در مواجهه با محیط پویای وب نهفته است. در پژوهش‌های دانشگاهی مجموعه داده‌ها غالباً ایستا و تمیز هستند، اما در وب واقعی، سیستم با محتوای تغییرپذیر، اطلاعات متناقض و نویز شدید روبه‌رو است که نقش بازرتبه‌بندی را حیاتی می‌سازد.

²⁹Cross-Encoders

³⁰Late Interaction

با وجود این اهمیت، بررسی ادبیات موضوع حاکی از چند شکاف پژوهشی است: نخست آنکه سامانه‌های تجاری جزئیات کمی و قابل‌بازتولیدی از تأثیر لایه‌ی بازرتبه‌بندی منتشر نمی‌کنند. دوم آنکه پژوهش‌هایی نظیر FreshLLMs اثبات کرده‌اند که مدل‌های زبانی در مواجهه با دانشی که به‌سرعت تغییر می‌کند دچار ضعف جدی می‌شوند و تزریق شواهد کاملاً به‌روز از وب ضروری است [۴۰]. از سوی دیگر، پژوهش Lost in the Middle نشان می‌دهد که نحوه‌ی چیدمان و موقعیت قرارگیری شواهد در بافتار ارائه‌شده به مدل، مستقیماً بر کیفیت خروجی اثرگذار است و مدل‌ها اطلاعاتِ میانه‌ی بافتار را نادیده می‌گیرند؛ موضوعی که ضرورت بازرتبه‌بندی دقیق را دوچندان می‌کند [۲۱].

بنابراین، توجیه علمی و هدف اصلی پژوهش حاضر آن است که با طراحی یک سیستم کنترل‌شده و اجرای مطالعه‌ی حذف^{۳۱} بر روی داده‌های پویای وب، این شکاف پژوهشی را پوشش دهد. در این راستا، برای ارزیابی دقیق‌تر علاوه بر معیارهای سنتی بازیابی، می‌توان از چارچوب‌های نوین ارزیابی نظیر RAGAS بهره برد تا مشخص شود پاسخ نهایی تا چه حد به شواهد ارائه‌شده وفادار (Faithful) بوده است [۳۵]. این تحلیل تجربی به صورت مستدل اثبات خواهد کرد که لایه‌ی بازرتبه‌بندی تا چه میزان قادر است نرخ توهم مدل را در محیط واقعی کاهش دهد.

³¹ Ablation Study

فصل ۴

معماری و روش پیشنهادی

۱-۴ مقدمه

هدف از این فصل، تشریح دقیق معماری فنی و جزئیات پیاده‌سازی سامانه‌ی پاسخ‌گویی هوشمند طراحی شده است. این سامانه با بهره‌گیری از معماری تولید افزوده با بازیابی^۱ [۱۲]، تلاش می‌کند تا محدودیت‌های مدل‌های زبانی بزرگ^۲ در زمینه‌ی دانش ایستا و پدیده‌ی توهم^۳ را از طریق اتصال به داده‌های بلادرنگ وب برطرف نماید.

بر اساس دسته‌بندی‌های نوین در ادبیات این حوزه، معماری این سامانه در دسته‌ی RAG پیشرفته و مدولار^۴ [۱۲] قرار می‌گیرد؛ زیرا علاوه بر یک فرآیند بازیابی ساده، از خط‌لوله‌های جانبی نظیر مسیریابی هوشمند، بسط پرس‌وجو و ارجاع‌دهی دقیق بهره می‌برد. در ادامه، اجزای مختلف سیستم، از مدیریت بافتار تا خط‌لوله‌ی پیشرفته‌ی بازیابی و بازرتبه‌بندی، به صورت مفصل شرح داده شده است.

۲-۴ معماری کلی سامانه

معماری پیشنهادی بر پایه‌ی یک ساختار «عامل‌گونه»^۵ طراحی شده است که قادر است بر اساس نوع پرسش کاربر، بین دو حالت عملیاتی مختلف سوئیچ نماید. این رویکرد را می‌توان یک معماری مبتنی بر مسیریابی^۶

^۱Retrieval-Augmented Generation (RAG)

^۲Large Language Models (LLMs)

^۳Hallucination

^۴Advanced / Modular RAG

^۵Agentic

^۶Router-based Architecture

دانست که هدف آن ایجاد تعادل میان کیفیت پاسخ‌دهی، هزینه‌ی محاسباتی و میزان تأخیر^۷ است.

۱-۲-۴ منطق تصمیم‌گیر برای سوئیچ حالت‌ها

سیستم در هر درخواست کاربر، بر اساس یک پارامتر کنترلی (is_web_search) تصمیم می‌گیرد که از کدام مسیر پاسخ‌دهی استفاده کند:

- **حالت پاسخ‌گویی عادی^۸:** در این حالت، سیستم صرفاً به دانش پارامتریک^۹ داخلی مدل زبانی اتکا می‌کند. این مسیر برای پرسش‌های خلاقانه، تحلیل‌های کلی یا گفت‌وگوهای ساده که نیازمند داده‌های لحظه‌ای نیستند، بهینه شده است. در این مسیر، تنها پرسش کاربر و تاریخچه‌ی گفت‌وگو به مدل ارسال می‌شود که منجر به پاسخی با کمترین تأخیر و هزینه می‌گردد.

- **حالت جست‌وجوی وب^{۱۰}:** زمانی که کاربر نیاز به اطلاعات به‌روز، فکت‌های دقیق یا منابع خارجی دارد، این حالت فعال می‌شود. در این مسیر، سیستم به جای پاسخ مستقیم، وارد یک خط لوله‌ی^{۱۱} پیچیده از «جست‌وجو → بازیابی → بازرتبه‌بندی → تولید» می‌گردد [۱۲].

این تفکیک باعث می‌شود که سیستم منابع محاسباتی سنگین‌تر جست‌وجوی وب و فراخوانی رابط‌های برنامه‌نویسی (API) خارجی را تنها در موارد ضروری به کار بگیرد.

۳-۴ مدیریت تاریخچه و بافتار

یکی از چالش‌های اصلی در سامانه‌های گفت‌وگو-محور، حفظ پیوستگی در تعاملات چندنوبتی^{۱۲} است. برای حل این مسئله، یک سیستم مدیریت بافتار^{۱۳} در لایه‌ی پایگاه‌داده^{۱۴} و سرویس‌های منطقی پیاده‌سازی شده است.

⁷Latency

⁸Standard Mode

⁹Parametric Knowledge

¹⁰Web Search Mode

¹¹Pipeline

¹²Multi-turn Conversations

¹³Context Management

¹⁴Database

۴-۳-۱ ذخیره‌سازی و بازیابی تاریخچه

تمام پیام‌های تبادل شده بین کاربر و دستیار در جداول پایگاه داده (Messages و Chats) ذخیره می‌شوند. هر پیام دارای یک برچسب نقش (role) است که مشخص می‌کند پیام توسط کاربر (user) یا دستیار (assistant) تولید شده است. هنگام ارسال هر درخواست جدید، سیستم تمام پیام‌های مربوط به آن شناسه‌ی یکتا (chat_id) را به ترتیب زمانی بازیابی می‌کند.

۴-۳-۲ تزریق بافتار به مدل

تاریخچه‌ی بازیابی شده به صورت یک رشته‌ی متنی ساختاریافته به مدل زبانی تزریق می‌شود. این کار باعث می‌شود مدل بتواند:

- رفع ابهام^{۱۵}: ضمیری مانند «آن» یا «این» را بر اساس پیام‌های قبلی شناسایی کند.
- پیوستگی منطقی: پاسخ‌های جدید را بر اساس جریان گفت‌وگو تنظیم کند و از تکرار مطالب قبلی بپرهیزد.

شایان ذکر است که اگرچه در نسخه‌ی فعلی سامانه تمام تاریخچه‌ی گفت‌وگو بازیابی و ارسال می‌شود، در توسعه‌های آتی می‌توان از تکنیک‌های فشرده‌سازی انتخابی بافتار^{۱۶} [۴۱] بهره برد تا ضمن کاهش مصرف توکن‌ها، تنها نوبت‌های مرتبط با پرسش نهایی به مدل تزریق شوند.

۴-۴ خط لوله‌ی جست‌وجوی وب

این بخش (خط لوله‌ی جست‌وجوی وب^{۱۷})، قلب تپنده‌ی سامانه است و از یک ساختار چندمرحله‌ای برای تبدیل یک پرسش مبهم کاربر به یک پاسخ مستند و دقیق استفاده می‌کند.

¹⁵Disambiguation

¹⁶Selective Context Compression

¹⁷Web Search Pipeline

۱-۴-۴ ماژول بسط پرس وجو

به دلیل آنکه پرسش‌های کاربران لزوماً برای موتورهای جست‌وجو بهینه نیستند، سیستم از ماژول بسط پرس وجو^{۱۸} برای افزایش میزان فراخوانی^{۱۹} استفاده می‌کند. بر اساس چارچوب‌های نوینی نظیر RQ-RAG [۴۲]، نادیده گرفتن ابهام در پرسش‌های پیچیده می‌تواند به افت کیفیت بازیابی منجر شود.

در این مرحله، پرسش کاربر به همراه تاریخچه‌ی گفت‌وگو به یک مدل زبانی ارسال می‌شود تا با استفاده از یک دستور (پرامپت) تخصصی، پرسش اصلی را از طریق بازنویسی و تجزیه، به ۳ تا ۵ کوئری^{۲۰} بهینه و متنوع تبدیل کند. خروجی این مرحله در قالب یک ساختار JSON است که شامل نسخه‌های مختلفی از پرسش (از نظر واژگان و زاویه‌ی دید) می‌باشد. این کار باعث می‌شود که اگر یک کوئری نتایج ضعیفی داشت، کوئری‌های دیگر بتوانند منابع طلایی را پیدا کنند.

۲-۴-۴ لایه‌ی بازیابی اولیه

در لایه‌ی بازیابی اولیه، کوئری‌های تولیدشده به طور موازی به رابط برنامه‌نویسی موتور جست‌وجوی تاویلی^{۲۱} ارسال می‌شوند. این موتور جست‌وجو که برای هوش مصنوعی بهینه‌سازی شده است، علاوه بر لینک‌ها، محتوای خام و پالایش‌شده (raw_content) صفحات وب را برمی‌گرداند.

این لایه از تکنیک‌های تشخیص و حذف کدهای زائد قالب^{۲۲} [۱۳] استفاده می‌کند تا نویزهایی مانند منوهای سایت، تبلیغات و پانویس‌های سایت^{۲۳} را حذف کرده و تنها متن اصلی مقاله یا صفحه را استخراج کند. این امر منجر به کاهش چشمگیر مصرف توکن‌ها در مرحله‌ی نهایی و جلوگیری از ورود داده‌های غیرمرتبط به مدل می‌شود.

۳-۴-۴ لایه‌ی بازرتبه‌بندی ترکیبی

در لایه‌ی بازرتبه‌بندی ترکیبی^{۲۴}، نتایج بازیابی‌شده از وب که معمولاً بر اساس شباهت‌های سطحی (مدل‌های رمزگذار دوگانه^{۲۵}) رتبه‌بندی شده‌اند، مورد ارزیابی مجدد قرار می‌گیرند. برای ارتقای معیار دقت^{۲۶}، این

¹⁸Query Expansion

¹⁹Recall

²⁰Query

²¹Tavily

²²Boilerplate Removal

²³Footers

²⁴Hybrid Reranking

²⁵Bi-Encoder

²⁶Precision

لایه با استفاده از مدل‌های رمزگذار متقاطع^{۲۷} پیاده‌سازی شده است [۱۵].

در این سامانه، از دو مدل پیشرو یعنی کوهیر^{۲۸} و جینا^{۲۹} استفاده شده است. برای بهینه‌سازی نهایی و افزایش پایداری سیستم، نتایج این دو مدل با استفاده از متد تلفیق رتبه متقابل^{۳۰} [۳۸] ترکیب می‌شوند:

- هر دو مدل (کوهیر و جینا) به طور مستقل به اسناد رتبه می‌دهند.
 - سیستم به جای میانگین‌گیری ساده از امتیازات، امتیاز نهایی هر سند را از مجموع معکوس رتبه‌های کسب‌شده‌ی آن در هر دو مدل محاسبه می‌کند.
 - اسنادی که در هر دو مدل رتبه‌ی بالایی کسب کرده‌اند، به شدت تشویق شده و به عنوان مرتبط‌ترین منابع شناسایی می‌شوند و سپس به لایه‌ی تولید پاسخ ارسال می‌گردند.
- این رویکرد باعث می‌شود خطاهای احتمالی هر یک از مدل‌ها توسط مدل دیگر جبران شده و سیستم در مواجهه با انواع مختلف محتوا پایداری عمل کند.

۴-۴-۴ تولید پاسخ نهایی و سیستم ارجاع‌دهی

در مرحله‌ی نهایی، متون پالایش‌شده و رتبه‌بندی‌شده به همراه پرسش کاربر و تاریخچه، در قالب یک پرامپت جامع به مدل زبانی ارسال می‌شود.

سیستم از یک دستورالعمل سخت‌گیرانه (WEB_SEARCH_SYSTEM_PROMPT) استفاده می‌کند که مدل را مجبور می‌کند:

- پاسخ را صرفاً بر اساس متون ارائه‌شده تولید کند (تولید مستند^{۳۱}).
 - هر ادعای فکت‌محور را با یک ارجاع شماره‌دار (مانند [2], [1]) دقیقاً به منبع مربوطه متصل کند.
- این رویکرد که در متون علمی به عنوان «تولید متن ارجاع‌دار»^{۳۲} شناخته می‌شود [۴۳]، بررسی‌پذیری پاسخ‌ها را به شدت افزایش می‌دهد. در نهایت، این ارجاعات در پایگاه‌داده ذخیره شده و در رابط کاربری به صورت لینک‌های قابل کلیک نمایش داده می‌شوند تا کاربر بتواند مستقیماً به منبع اصلی مراجعه کند.

²⁷Cross-Encoder

²⁸Cohere Rerank

²⁹Jina Reranker

³⁰Reciprocal Rank Fusion (RRF)

³¹Grounded Generation

³²Attributed Text Generation (ATG)

۵-۴ جزئیات فنی پیاده‌سازی

برای دستیابی به کارایی بالا و قابلیت گسترش، از پشته‌ی فناوری^{۳۳} زیر استفاده شده است:

- زبان برنامه‌نویسی: پایتون ۳.۱۰ +^{۳۴} (به دلیل غنای کتابخانه‌ها در حوزه‌ی هوش مصنوعی و پردازش داده).
- فریم‌ورک بک‌اند^{۳۵}: فست‌ای‌پی‌آی^{۳۶} (به دلیل پشتیبانی از async/await که برای فراخوانی‌های موازی در سرویس‌های بازیابی و بازرتبه‌بندی حیاتی است).
- مدل زبانی (LLM): Gemini 2.5 Flash (به دلیل پنجره‌ی بافتار بسیار بزرگ، سرعت بالا و توانمندی عالی در استدلال‌های مبتنی بر ارجاع)^[۴۴].
- پایگاه‌داده: اس‌کیوال‌لایت^{۳۷} با استفاده از ابزار SQLAlchemy (برای مدیریت بهینه‌ی داده‌های کاربران، چت‌ها و ارجاعات).
- رابط کاربری (فرانت‌اند^{۳۸}): تکنولوژی‌های HTML5، جاوا اسکریپت خالص^{۳۹} و Tailwind CSS v4 (برای ایجاد یک محیط مدرن، سریع و بدون نیاز به فریم‌ورک‌های سنگین).

۶-۴ مزایا و محدودیت‌های روش پیشنهادی

مزایا:

- دقت بالا و کاهش توهم: به دلیل استفاده از لایه‌ی بازرتبه‌بندی^(۴۰) و اجبار مدل به ارجاع‌دهی، احتمال تولید اطلاعات ساختگی به شدت کاهش یافته است.
- به‌روز بودن مطلق: سیستم به جای اتکا به دانش قدیمی مدل، در لحظه از وب اطلاعات استخراج می‌کند.

³³Tech Stack

³⁴Python 3.10+

³⁵Backend Framework

³⁶FastAPI

³⁷SQLite

³⁸Frontend

³⁹Vanilla JavaScript

⁴⁰Cross-Encoder

- شفافیت و قابلیت بازبینی: کاربر می‌تواند هر بخش از پاسخ را با کلیک بر روی ارجاعات، در منبع اصلی بررسی کند.

محدودیت‌ها:

- تأخیر در پاسخ‌دهی^(۴۱): به دلیل ماهیت چندمرحله‌ای سیستم (تولید کوئری → بازیابی از وب → بازرتبه‌بندی → تولید نهایی)، زمان پاسخ‌دهی در حالت جست‌وجوی وب بیشتر از حالت عادی است و ممکن است برای کاربردهای فوق‌سریع مناسب نباشد.
- وابستگی به سرویس‌های خارجی: عملکرد بهینه‌ی سیستم مستقیماً به پایداری و در دسترس بودن وب‌سرویس‌های تاویلی، کوهیر و گوگل وابسته است.
- هزینه‌ی عملیاتی: هر درخواست در حالت وب، اعتبار چندین وب‌سرویس را به طور همزمان مصرف می‌کند که در استقرار در مقیاس‌های بزرگ تجاری نیاز به پیاده‌سازی لایه‌های کنترل هزینه و کشینگ^{۴۲} خواهد داشت.

⁴¹Latency

⁴²Caching

فصل ۵

نتایج جدید

در این فصل نتایج جدید به دست آمده در پایان نامه توضیح داده می شود. در صورت نیاز می توان نتایج جدید را در قالب چند فصل ارائه نمود. همچنین در صورت وجود پیاده سازی، بهتر است نتایج پیاده سازی را در فصل مستقلی پس از این فصل قرار داد.

فصل ۶

نتیجه‌گیری

در این فصل، ضمن جمع‌بندی نتایج جدید ارائه‌شده در پایان‌نامه یا رساله، مسائل باز باقی‌مانده و همچنین پیشنهادهایی برای ادامه‌ی کار ارائه می‌شوند.

Bibliography

- [1] T. B. Brown, B. Mann, N. Ryder, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, 2020.
- [2] C. D. Manning, P. Raghavan, and H. Schütze. *Introduction to Information Retrieval*. Cambridge University Press, Cambridge, 2008.
- [3] S. Robertson and H. Zaragoza. The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends in Information Retrieval*, 4(1–2):1–174, 2009.
- [4] J. Kasai, K. Sakaguchi, Y. Takahashi, et al. Realtime qa: What’s the answer right now? *arXiv preprint arXiv:2207.13332*, 2024.
- [5] L. Huang, W. Yu, W. Ma, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *ACM Computing Surveys*, 2025.
- [6] S. Lin, J. Hilton, and O. Evans. Truthfulqa: Measuring how models mimic human falsehoods. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics*, pages 3214–3252, 2022.
- [7] AWS Startups. Reimagining search: Perplexity drives productivity with generative ai-powered answer engine. Amazon Web Services, 2023.
- [8] J. Ribas. Building the new bing. Microsoft Bing Blogs, 2023.
- [9] Google. Google i/o 2024: New generative ai experiences in search. Google The Keyword Blog, 2024.
- [10] T. Gao, H. Yen, J. Yu, and D. Chen. Enabling large language models to generate text with citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 6465–6488, 2023.

- [11] P. Lewis, E. Perez, A. Piktus, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [12] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang, and H. Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2024.
- [13] C. Kohlschütter, P. Fankhauser, and W. Nejdl. Boilerplate detection using shallow text features. In *Proceedings of the Third ACM International Conference on Web Search and Data Mining*, pages 441–450, 2010.
- [14] H. Trivedi, N. Balasubramanian, T. Khot, and A. Sabharwal. Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 10014–10037, 2023.
- [15] N. Reimers and I. Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992, 2019.
- [16] S. Brin and L. Page. The anatomy of a large-scale hypertextual web search engine. In *Proceedings of the Seventh International World Wide Web Conference*, volume 30, pages 107–117, 1998.
- [17] G. Salton and C. Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988.
- [18] L. Page, S. Brin, R. Motwani, and T. Winograd. The pagerank citation ranking: Bringing order to the web. Technical report, Stanford InfoLab, 1999.
- [19] D. Metzler, Y. Tay, D. Bahri, and M. Najork. Rethinking search: Making domain experts out of dilettantes. *ACM SIGIR Forum*, 55(1), 2021.
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, . Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017.
- [21] N. F. Liu, K. Lin, J. Hewitt, et al. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.

- [22] K. Guu, K. Lee, Z. Tung, P. Pasupat, and M.-W. Chang. Retrieval augmented language model pre-training. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119, pages 3929–3938, 2020.
- [23] J. Johnson, M. Douze, and H. Jégou. Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547, 2019.
- [24] V. Karpukhin, B. Oğuz, S. Min, et al. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020.
- [25] C. Castillo and B. D. Davison. Adversarial web search. *Foundations and Trends in Information Retrieval*, 4(5):377–486, 2010.
- [26] Z. Yang, P. Qi, S. Zhang, et al. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 2369–2380, 2018.
- [27] R. Nakano, J. Hilton, S. Balaji, et al. Webgpt: Browser-assisted question-answering with human feedback. *arXiv preprint arXiv:2112.09332*, 2021.
- [28] T. Schick, J. Dwivedi-Yu, R. Dessì, et al. Toolformer: Language models can teach themselves to use tools. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [29] X. Ma, Y. Gong, P. He, H. Zhao, and N. Duan. Query rewriting in retrieval-augmented large language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5303–5315, 2023.
- [30] S. Yao, J. Zhao, D. Yu, et al. React: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations*, 2023.
- [31] Z. Jiang, F. F. Xu, L. Gao, et al. Active retrieval augmented generation. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 7969–7992, 2023.
- [32] Z. Wu, Y. Luan, H. Rashkin, et al. Conqrr: Conversational query rewriting for retrieval with reinforcement learning. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 10000–10014, 2022.
- [33] R. Nogueira and K. Cho. Passage re-ranking with bert. *arXiv preprint arXiv:1901.04085*, 2019.

- [34] N. Thakur, N. Reimers, A. Rücklé, et al. Beir: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Advances in Neural Information Processing Systems Datasets and Benchmarks*, 2021.
- [35] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert. Ragas: Automated evaluation of retrieval augmented generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 2024.
- [36] A. Singhal. Introducing the knowledge graph: Things, not strings. Official Google Blog, 2012.
- [37] Google Search Central. Ai features and your website. Google Developers Documentation, 2024.
- [38] G. V. Cormack, C. L. Clarke, and S. Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pages 758–759, 2009.
- [39] O. Khattab and M. Zaharia. Colbert: Efficient and effective passage search via contextualized late interaction over bert. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 39–48, 2020.
- [40] T. Vu, M. Iyyer, X. Wang, N. Constant, J. Wei, J. Wei, C. Tar, Y.-H. Sung, D. Zhou, Q. Le, and T. Luong. Freshllms: Refreshing large language models with search engine augmentation. *arXiv preprint arXiv:2310.03214*, 2023.
- [41] W. Wang, X. Chen, D. Miao, H. Zhang, X. Qin, X. Gu, and P. Lu. Optimizing chatbot responsiveness: Automated history context selector via three-way decision for multi-turn dialogue large language models. *Expert Systems with Applications*, 2025.
- [42] C.-M. Chan, C. Xu, R. Yuan, H. Luo, W. Xue, Y. Guo, and J. Fu. Rq-rag: Learning to refine queries for retrieval augmented generation. *arXiv preprint arXiv:2404.00610*, 2024.
- [43] S. Xia, X. Wang, J. Liang, Y. Zhang, W. Zhou, J. Deng, F. Yu, and Y. Xiao. Ground every sentence: Improving retrieval-augmented llms with interleaved reference-claim generation. *arXiv preprint arXiv:2407.01796*, 2024. Accepted to NAACL 2025 Findings.

- [44] Google DeepMind. Google i/o 2024: Gemini 1.5 flash and updates to the gemini family. Google DeepMind Blog, 2024.

واژه‌نامه

الف

ابتکاری heuristic.....
ابعاد بالا high dimensions.....
اریب bias.....
آستانه threshold.....
اصل لانه‌ی کبوتری pigeonhole principle.....
ان‌پی-سخت NP-Hard.....
انتقال transition.....

ت

تجربی experimental.....
تراکم density.....
تقریب approximation.....
تقسیم‌بندی partition.....
توری mesh.....
توزیع‌شده distributed.....

ب

برخط online.....
برنامه‌ریزی خطی linear programming.....
بهینه optimum.....
بیشینه maximum.....

ج

جدایپذیر separable.....
جعبه سیاه black box.....
جویبار داده data stream.....

پ

پرت outlier.....
پرسمان query.....
پوشش cover.....
پیچیدگی complexity.....

ح

حدی extreme.....
حریصانه greedy.....

خ

خوشه cluster.....
خطی linear.....

د

داده data
داده کاوی data mining
داده‌ی پرت outlier data
دو برابر سازی doubling
دودویی binary

ر

رأس vertex
رسمی formal

ز

زیرخطی sublinear

س

سرشکن amortized
سلسله مراتبی hierarchichal

ش

شبه کد pseudocode
شیء object

ص

صدق پذیری satisfiability

غ

غلبه dominate

ف

فاصله distance
فضا space

ق

قطعی deterministic

ک

کارا efficient
کاندیدا candidate
کمینه minimum

م

مجموعه set
مجموعه هسته coreset
مسطح planar
موازی سازی parallelization
میان گیر buffer

ن

نابه جایی inversion
ناوردا invariant
نقطه‌ی مرکزی center point
نیم فضا half space

ه

هزینه‌ی آشوب price of anarchy (POA)

ی

یال edge

پیوست آ

مطالب تکمیلی

پیوست‌های خود را در صورت وجود می‌توانید در این قسمت قرار دهید.

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the `XYLATEX Persian` package for the `LATEX` typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, `XYLATEX Persian`



Sharif University of Technology
Department of Computer Engineering

B.Sc. Thesis

Intelligent Web Search Engine

By:

Ali Hashemian

Supervisor:

Dr. Hamid Beigi

June 2026