



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی
مهندسی کامپیوتر

موتور جستجوی هوشمند وب

نگارش

علی هاشمیان

استاد راهنما

دکتر حمید بیگی

خرداد ۱۴۰۵



سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

چکیده

نگارش پایان‌نامه علاوه بر بخش پژوهش و آماده‌سازی محتوا، مستلزم رعایت نکات فنی و نگارشی دقیقی است که در تهیه‌ی یک پایان‌نامه‌ی موفق بسیار کلیدی و مؤثر است. از آن جایی که بسیاری از نکات فنی مانند قالب کلی صفحات، شکل و اندازه‌ی قلم، صفحات عنوان و غیره در تهیه‌ی پایان‌نامه‌ها یکسان است، با استفاده از نرم‌افزار حروف‌چینی زی‌تک و افزونه‌ی زی‌پرشین یک قالب استاندارد برای تهیه‌ی پایان‌نامه‌ها ارائه گردیده است. این قالب می‌تواند برای تهیه‌ی پایان‌نامه‌های کارشناسی و کارشناسی ارشد و نیز رساله‌های دکتری مورد استفاده قرار گیرد. این نوشتار به طور مختصر نحوه‌ی استفاده از این قالب را نشان می‌دهد.

کلیدواژه‌ها: پایان‌نامه، حروف‌چینی، قالب، زی‌پرشین

فهرست مطالب

۱	مقدمه	۱
۱-۱	بیان مسئله	۱
۲-۱	اهمیت و ضرورت موضوع	۲
۳-۱	چالش‌های معماری استاندارد RAG در فضای وب	۳
۴-۱	اهداف پژوهش	۳
۵-۱	پرسش‌های پژوهش	۴
۶-۱	نوآوری و سهم کار	۵
۷-۱	روش کلی انجام کار	۵
۸-۱	ساختار پایان‌نامه	۶
۲	مفاهیم پایه و مبانی نظری	۷
۱-۲	موتورهای جستجوی سنتی	۷
۲-۲	مدل‌های زبانی بزرگ ^۱ (LLMs) و پاسخ‌گویی محاوره‌ای	۸
۳-۲	تولید افزوده شده با بازیابی ^۲ (RAG)	۹
۴-۲	تفاوت RAG کلاسیک با RAG مبتنی بر وب (چالش‌های اساسی)	۱۰
۵-۲	سامانه‌های مبتنی بر جستجوی وب (Search-Augmented LLMs) و ابزارهای API	۱۱
۶-۲	نقش تاریخچه گفتگو در پاسخ‌گویی محاوره‌ای	۱۲

^۱Large Language Models

^۲Retrieval-Augmented Generation

۱۲	۷-۲ بازرتبه‌بندی ^۳ یا Re-ranking
۱۳	۸-۲ معیارهای ارزیابی سامانه‌ها ^۴
۱۴	۳ کارهای پیشین
۱۴	۱-۳ مسائل خوشه‌بندی
۱۶	۲-۳ خوشه‌بندی k -مرکز
۱۸	۳-۳ مدل جویبار داده
۱۹	۴-۳ تقریب‌پذیری
۲۰	۴ نتایج جدید
۲۱	۵ نتیجه‌گیری
۲۲	مراجع
۲۴	واژه‌نامه
۲۶	آ مطالب تکمیلی

^۳Re-ranking

^۴System Evaluation Metrics

فهرست جداول

۱-۳ نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی ۱۹

فهرست تصاویر

۱۶		۱-۳ نمونه‌ای از مسئله‌ی ۲-مرکز
۱۷		۲-۳ نمونه‌ای از مسئله‌ی ۲-مرکز با داده‌های پرت

فصل ۱

مقدمه

نخستین فصل این پایان‌نامه به معرفی مسئله، بیان اهمیت و ضرورت موضوع، تبیین چالش‌های موجود در معماری‌های رایج، اهداف پژوهش و در نهایت معرفی ساختار کلی پایان‌نامه می‌پردازد. در این فصل، تصویری جامع از انگیزه‌های انجام این تحقیق و مسیر پیش رو ارائه می‌گردد.

۱-۱ بیان مسئله

در سال‌های اخیر، ظهور و تکامل مدل‌های زبانی بزرگ^۱ تحولی بنیادین و پارادایم‌شیفتم‌گیری در نحوه تعامل انسان با ماشین، پردازش زبان طبیعی و روش‌های دسترسی به اطلاعات ایجاد کرده است. با این وجود، پارادایم سنتی بازیابی اطلاعات و جستجو در وب همچنان با چالش‌ها و کاستی‌های جدی مواجه است. موتورهای جستجوی سنتی، عمدتاً بر اساس الگوریتم‌های تطبیق کلیدواژه^۲ و تحلیل پیوندها عمل می‌کنند. این سیستم‌ها به جای ارائه پاسخ نهایی و تحلیلی به کاربر، صرفاً فهرستی از پیوندها (لینک‌ها) را برمی‌گردانند که بار شناختی مطالعه، جمع‌آوری و استخراج پاسخ نهایی را به طور کامل بر دوش کاربر قرار می‌دهد.

از سوی دیگر، مدل‌های زبانی بزرگ با وجود توانمندی شگرف در درک عمیق بافتار و تولید زبان طبیعی روان، دارای محدودیت‌های ذاتی و ساختاری مهمی هستند. نخستین محدودیت، اتکای این مدل‌ها به «دانش ایستا»^۳ است؛ به این معنا که حافظه پارامتریک^۴ آن‌ها محدود به داده‌هایی است که تا زمان پایان

¹Large Language Models (LLMs)

²Keyword-matching

³Static Knowledge

⁴Parametric Memory

فاز آموزش^۵ دریافت کرده‌اند. به همین دلیل، این مدل‌ها در پاسخ‌گویی به پرسش‌هایی که نیازمند آگاهی از رویدادهای لحظه‌ای، اخبار روز و داده‌های بلادرنگ هستند، کاملاً ناتوان عمل می‌کنند.

محدودیت دوم و به مراتب خطرناک‌تر، پدیده‌ای به نام «توهم»^۶ است. مدل‌های زبانی به گونه‌ای طراحی شده‌اند که همواره توالی کلمات بعدی را با بیشترین احتمال تولید کنند؛ بنابراین در صورت عدم آگاهی از فکت‌های واقعی پیرامون یک موضوع، ممکن است پاسخ‌هایی کاملاً ساختگی، نامعتبر اما با لحنی به شدت متقاعدکننده و ساختاریافته تولید نمایند.

بر این اساس، مسئله اصلی پژوهش حاضر، غلبه بر محدودیت‌های متقابل هر دو سیستم (یعنی رویکرد منفعل موتورهای جستجوی سنتی و توهم‌زایی مدل‌های زبانی منفرد) از طریق طراحی، پیاده‌سازی و بررسی یک سامانه پاسخ‌گویی هوشمند است. سامانه‌ای عامل‌گونه که بتواند با تحلیل دقیق نیت کاربر و درک تاریخیچه تعاملات (گفتگوها)، پرسش‌های جستجوی بهینه‌ای تولید کرده، فضای وب را در لحظه کاوش کند و با بهره‌گیری از تکنیک‌های پیشرفته پردازش زبان و بازرتبه‌بندی^۷، پاسخی تحلیلی، به‌روز و کاملاً مستند (همراه با ارجاع به منابع) ارائه دهد.

۲-۱ اهمیت و ضرورت موضوع

با تغییر الگوی مصرف اطلاعات در عصر دیجیتال، سطح انتظارات کاربران از سیستم‌های بازیابی اطلاعات دگرگون شده است. کاربران امروزی انتظار دارند به جای جستجوی دستی در میان انبوهی از صفحات وب، پاسخ‌های مستقیم، دقیق، به‌روز و قابل استناد را در قالب یک گفتگوی محاوره‌ای و روان دریافت کنند. ترکیب موتورهای جستجو با هوش مصنوعی مولد^۸، راهکاری است که معماری‌های پیشگامی نظیر پرپلکسیتی^۹، بینگ کوپایلوت^{۱۰} و جستجوی هوشمند گوگل^{۱۱} به سوی آن حرکت کرده‌اند و اهمیت استراتژیک و تجاری این حوزه را در سطح جهانی به اثبات رسانده‌اند.

ضرورت بنیادین انجام این پژوهش در این است که استفاده‌ی صرف و بدون پشتوانه از مدل‌های زبانی در حوزه‌های حساس (نظیر حوزه‌های پزشکی، حقوقی، علمی و خبری) که نیازمند دقت بالا و فکت‌های اثبات‌شده هستند، به دلیل خطرات ناشی از توهم مدل، غیرقابل اعتماد و بعضاً آسیب‌زا است. متصل کردن

^۵Training Cut-off

^۶Hallucination

^۷Reranking

^۸Generative AI

^۹Perplexity

^{۱۰}Bing Copilot

^{۱۱}Google AI Search

مدل زبانی به جریان اطلاعات پویای وب که اصطلاحاً اتصال به زمینه‌ی وب^{۱۲} نامیده می‌شود، نه تنها معضل اطلاعات منقضی‌شده را برطرف می‌سازد، بلکه با فراهم آوردن امکان ارجاع‌دهی دقیق به منابع و مراجع معتبر^{۱۳}، شفافیت و اعتماد کاربر به سیستم را به شکل چشمگیری افزایش می‌دهد.

۳-۱ چالش‌های معماری استاندارد RAG در فضای وب

در ادبیات موضوع فعلی، معماری «تولید افزوده با بازیابی» یا رگ^{۱۴} به عنوان راهکاری استاندارد و اثبات‌شده برای تزریق دانش خارجی و غیرپارامتریک به مدل‌های زبانی شناخته می‌شود. با این حال، خط لوله‌ی^{۱۵} RAG سنتی عمدتاً برای کار بر روی اسناد ثابت، ساختاریافته و آفلاین (مانند پایگاه داده‌ای از فایل‌های سازمانی) طراحی شده است و در مواجهه با فضای وب با چالش‌های فنی و معنایی اساسی روبرو است. فضای وب، محیطی به شدت پویا، پرنویز، ناهمگن و غیرقابل پیش‌بینی است. در RAG سنتی، اسناد پیش از استفاده، طی یک فرآیند آفلاین پردازش، پاک‌سازی و قطعه‌بندی^{۱۶} شده و در یک پایگاه داده برداری^{۱۷} ذخیره می‌گردند. اما در فرآیند وب‌گردی در لحظه^{۱۸}، زمان کافی برای این پیش‌پردازش عمیق وجود ندارد. سیستم باید بتواند در کسری از ثانیه، محتوای صفحات وب بازیابی‌شده را که حاوی حجم زیادی از تبلیغات، کدهای مخرب، ساختارهای پیچیده HTML و نویزهای بصری هستند، دریافت و پالایش کند. همچنین در RAG سنتی، معمولاً پرسش اولیه کاربر مستقیماً برای جستجوی معنایی استفاده می‌شود؛ اما در وب، پرسش اولیه کاربر ممکن است مبهم یا چندوجهی باشد و برای یافتن پاسخ جامع، نیازمند تجزیه به چندین پرس‌وجوی فرعی و مستقل^{۱۹} باشد؛ قابلیت‌هایی که در سیستم‌های جستجوی معنایی پایه تعبیه نشده و نیازمند یک مازول تصمیم‌گیر (عامل هوشمند) برای مدیریت بسط پرس‌وجوهاست.

۴-۱ اهداف پژوهش

هدف اصلی این پژوهش، طراحی، توسعه و ارزیابی یک موتور جستجوی هوشمند و گفتگو‌محور است که توانایی استخراج بلادرنگ اطلاعات از وب و ترکیب آن با قدرت استدلال مدل‌های زبانی را داشته باشد.

¹²Web Grounding

¹³Citations

¹⁴Retrieval-Augmented Generation (RAG)

¹⁵Pipeline

¹⁶Chunking

¹⁷Vector Database

¹⁸Real-time Web Browsing

¹⁹Multi-query Generation

در راستای تحقق این هدف کلان، اهداف خرد زیر دنبال می‌شوند:

- مطالعه، بررسی و تحلیل معماری سامانه‌های نوین جستجوی هوشمند مبتنی بر مدل‌های زبانی بزرگ.
- طراحی یک سامانه ترکیبی دوحالته با قابلیت تشخیص خودکار و سوئیچ بین «پاسخ‌گویی عادی (مبتنی بر دانش پارامتریک)» و «پاسخ‌گویی مبتنی بر بازیابی از وب».
- پیاده‌سازی مکانیزم آگاهی از بافتار^{۲۰} با استفاده از تزریق تاریخچه گفتگوها جهت تولید پاسخ‌های پیوسته، منطقی و چندنوبتی^{۲۱}.
- بررسی و پیاده‌سازی مکانیزم‌های پیشرفته‌ی بازمردهی و بازرتبه‌بندی پرس‌وجوها و متون استخراج‌شده از وب برای یافتن مرتبط‌ترین قطعات متنی و کاهش نویز.
- طراحی یک چارچوب ارزیابی جامع برای سنجش عملکرد و کیفیت خروجی سامانه پیشنهادی روی مجموعه‌ای از پرسش‌های چالشی، مبهم و نیازمند اطلاعات لحظه‌ای.

۵-۱ پرسش‌های پژوهش

این پژوهش در پی یافتن پاسخ علمی، مستدل و قابل اندازه‌گیری برای پرسش‌های اساسی زیر است:

- آیا ادغام جستجوی وبِ بلادرنگ با مدل‌های زبانی بزرگ، موجب کاهش معنادار پدیده توهم و بهبود دقت فاکچوال^{۲۲} در پاسخ‌گویی به پرسش‌های دانش‌محور می‌شود؟
- آیا به‌کارگیری تکنیک‌ها و مدل‌های بازرتبه‌بندی^{۲۳} بر روی نتایج خام استخراج‌شده از صفحات وب، کیفیت، انسجام و ارتباط معنایی پاسخ نهایی ارائه‌شده به کاربر را ارتقا می‌دهد؟
- در یک محیط تعاملی و چندنوبتی، تزریق تاریخچه گفتگوها به مازول تولید پرس‌وجو، تا چه میزان در درک بهتر نیت پنهان کاربر و تولید کلیدواژه‌های جستجوی دقیق‌تر مؤثر است؟

²⁰Context-awareness

²¹Multi-turn

²²Factual Accuracy

²³Reranker

۱-۶ نوآوری و سهم کار

سهم اصلی و نوآوری این پژوهش، فراتر رفتن از یک رابط برنامه‌نویسی^{۲۴} ساده و توسعه یک سیستم یکپارچه، ماژولار و عامل‌گونه^{۲۵} است که به صورت خودمختار توانایی مدیریت جریان اطلاعات را داراست. دستاوردهای کلیدی و نوآوری‌های این پایان‌نامه عبارتند از:

- طراحی و پیاده‌سازی یک سامانه‌ی پردازشی هوشمند با قابلیت تشخیص خودکار نیاز به جستجوی خارجی (کاهش سربار سیستم با طراحی دوحالت).
- توسعه یک ماژول تخصصی برای تولید و بسط پرس‌وجو^{۲۶}، که قادر است با تحلیل ترکیب سؤال فعلی کاربر و بافتار تاریخیچه چت، چندین پرس‌وجوی مستقل و بهینه برای موتور جستجوی وب تولید نماید.
- توسعه الگوریتمی برای تجمیع اطلاعات پراکنده از منابع مختلف وب، پالایش نویزهای HTML، و تولید یک پاسخ نهایی جامع همراه با سیستم ارجاع‌دهی درون‌متنی^{۲۷}.
- طراحی و اجرای یک خط لوله ارزیابی علمی برای مقایسه عملکرد سیستم در حالت پایه^{۲۸} در برابر حالت مجهز به مدل‌های بازرتبه‌بندی.

۱-۷ روش کلی انجام کار

روند کلی انجام این پژوهش مبتنی بر توسعه یک خط لوله (Pipeline) پردازشی چندمرحله‌ای و هوشمند است. در این فرآیند، ابتدا درخواست کاربر دریافت شده و همراه با تاریخچه گفتگوهای پیشین به ماژول تحلیل نیت ارسال می‌گردد. سیستم با بهره‌گیری از یک مدل زبانی پایه، نیاز اطلاعاتی کاربر را تحلیل کرده و در صورت تشخیص نیاز به داده‌های به‌روز، آن را به چند پرس‌وجوی (Query) بهینه و مجزا می‌شکند. در گام بعدی، این پرس‌وجوها از طریق رابط موتور جستجو به شبکه وب ارسال شده و صفحات مرتبط شناسایی و بارگیری (Scrape) می‌شوند. محتوای متنی این صفحات استخراج شده و به قطعات کوچکتر

²⁴API

²⁵Agentic

²⁶Query Expansion

²⁷In-text Citation

²⁸Basic Web Retrieval

تقسیم می‌گردد. سپس به کمک یک مدل بازرتبه‌بند مبتنی بر شبکه‌های عصبی متقاطع^{۲۹}، این قطعات متنی بر اساس بیشترین میزان هم‌پوشانی معنایی با نیاز کاربر، فیلتر و مرتب‌سازی می‌شوند.

در نهایت، متونِ پالایش‌شده‌ی برتر به عنوان «بافتارِ دانش» به دستورالعمل^{۳۰} مدل زبانی بزرگ تزریق می‌شوند تا مدل بتواند پاسخی نهایی، دقیق، مستدل و ارجاع‌دار تولید کرده و به کاربر نمایش دهد. در فاز پایانی پژوهش نیز، کیفیت خروجی‌های این معماری با استفاده از متریک‌های ارزیابی کیفی رایج در حوزه پردازش زبان طبیعی سنجیده و تحلیل خواهند شد.

۸-۱ ساختار پایان‌نامه

[این بخش پس از نهایی شدن نگارش فصول بعدی پایان‌نامه تکمیل خواهد شد. در این قسمت طی یک یا دو پاراگراف، محتوای فصول دوم (مروری بر ادبیات موضوع)، سوم (روش‌شناسی و معماری سیستم پیشنهادی)، چهارم (پیاده‌سازی، آزمایش‌ها و ارزیابی نتایج) و پنجم (نتیجه‌گیری و کارهای آتی) به اختصار شرح داده خواهد شد.]

²⁹Cross-encoder Reranker

³⁰Prompt

فصل ۲

مفاهیم پایه و مبانی نظری

هدف از این فصل، ارائه پایه‌های علمی، نظری و فنی مفاهیمی است که در طراحی و پیاده‌سازی سامانه‌های هوشمند مبتنی بر مدل‌های زبانی^۱ و جستجوی وب نقش اساسی ایفا می‌کنند. پیش از ورود به معماری دقیق سیستم پیشنهادی در فصول آتی، درک عمیق مکانیزم‌های سنتی بازیابی اطلاعات^۲، بررسی دقیق محدودیت‌های مدل‌های زبانی، معماری نوین تولید افزوده شده با بازیابی^۳ (RAG) و چالش‌های پیچیده تعامل با محیط پویای وب الزامی است. این فصل به عنوان پیش‌نیازی مستحکم برای درک منطق، الگوریتم‌ها و نوآوری‌های مطرح شده در ادامه پایان‌نامه عمل می‌کند.

۲-۱ موتورهای جستجوی سنتی

پیش از ظهور مدل‌های زبانی هوشمند و سامانه‌های تولیدگر^۴، دسترسی به اطلاعات در وب عمدتاً از طریق موتورهای جستجوی سنتی^۵ انجام می‌پذیرفت. معماری و کارکرد این موتورها بر چهار پایه اصلی استوار است:

۱. خزش^۶: (Crawling) ربات‌های نرم‌افزاری^۷ صفحات وب را به صورت گراف‌پیمایی^۸ پیمایش کرده و محتوای آن‌ها را برای پردازش‌های بعدی جمع‌آوری می‌کنند.

¹Language Models

²Information Retrieval

³Retrieval-Augmented Generation

⁴Generative Systems

⁵Traditional Search Engines

⁶Crawling

⁷Software Bots

⁸Graph Traversal

۲. نمایه‌سازی^۹: (Indexing) محتوای جمع‌آوری شده پس از پیش‌پردازش متنی^{۱۰} (نظیر حذف کلمات توقف^{۱۱} و ریشه‌یابی^{۱۲}) در ساختارهای داده‌ای بهینه‌سازی شده مانند نمایه‌ی معکوس^{۱۳} (In-verted Index) ذخیره می‌شود تا جستجو با پیچیدگی زمانی حداقل و سرعت بالا انجام پذیرد.

۳. بازیابی و رتبه‌بندی^{۱۴} (Retrieval & Ranking) هنگامی که کاربر پرس‌وجویی^{۱۵} ارسال می‌کند، سیستم با استفاده از الگوریتم‌های آماری نظیر $TF - IDF$ یا $BM25$ ، مرتبط‌ترین اسناد را بازیابی کرده و بر اساس فاکتورهای چون ارتباط معنایی کلیدواژه‌ها، اعتبار دامنه^{۱۶} (مانند الگوریتم $PageRank$) و لینک‌های ورودی^{۱۷} مرتب می‌کند.

۴. نمایش نتایج: خروجی فرآیند به صورت لیستی از پیوندها (Links) و خلاصه‌های کوتاه^{۱۸} (Snippets) به کاربر ارائه می‌شود.

اگرچه این موتورها در یافتن صفحات وب بسیار مقیاس‌پذیر^{۱۹} و کارآمد هستند، اما در تولید پاسخ‌های مستقیم، استنتاج منطقی^{۲۰} و ترکیب اطلاعات از چندین منبع متمایز برای پاسخ‌گویی به سؤالات پیچیده ناتوان‌اند. این محدودیت بنیادین، نقطه شروع گذار پژوهشگران به سمت سامانه‌های هوشمندتر مبتنی بر هوش مصنوعی بود.

۲-۲ مدل‌های زبانی بزرگ^{۲۱} (LLMs) و پاسخ‌گویی محاوره‌ای

مدل‌های زبانی بزرگ شبکه‌های عصبی عمیقی^{۲۲} (غالباً مبتنی بر معماری ترانسفورمر^{۲۳} و مکانیزم توجه^{۲۴} یا Attention) هستند که روی حجم عظیمی از داده‌های متنی آموزش دیده‌اند. این مدل‌ها قادرند با پیش‌بینی توکن بعدی^{۲۵} با استفاده از احتمالات ریاضی، متن‌هایی بسیار روان، منسجم و انسان‌گونه تولید کنند. با

⁹Indexing

¹⁰Text Preprocessing

¹¹Stop Words

¹²Stemming

¹³Inverted Index

¹⁴Retrieval & Ranking

¹⁵Query

¹⁶Domain Authority

¹⁷Inbound Links

¹⁸Snippets

¹⁹Scalable

²⁰Logical Inference

²¹Large Language Models

²²Deep Neural Networks

²³Transformer Architecture

²⁴Attention Mechanism

²⁵Next Token Prediction

تکنیک‌هایی نظیر مهندسی پرامپت^{۲۶} می‌توان رفتار این مدل‌ها را برای انجام وظایف خاص هدایت کرد. با این وجود، استفاده مستقیم از این مدل‌ها به عنوان موتور پاسخ‌گویی دارای چالش‌های جدی زیر است:

- **توهم^{۲۷}: (Hallucination)** مدل‌های زبانی گاهی پاسخ‌هایی تولید می‌کنند که از نظر قواعد گرامری کاملاً صحیح و متقاعدکننده به نظر می‌رسند، اما از نظر حقایق بیرونی کاملاً ساختگی و غلط هستند.
- **دانش ایستا و قدیمی^{۲۸}: (Static Knowledge)** دانش جاسازی‌شده در وزن‌های مدل محدود به داده‌هایی است که تا زمان آموزش^{۲۹} (Knowledge Cut-off) دیده‌است. بنابراین، در مورد اخبار، رویدادهای جدید یا اطلاعات بلادرنگ هیچ آگاهی ندارد.
- **نبود ارجاع‌پذیری^{۳۰}: of (Lack Attribution)** مدل به صورت ذاتی نمی‌تواند نشان دهد که پاسخ تولید شده را از کدام منبع یاد گرفته است، که این امر اعتمادپذیری^{۳۱} سیستم را در کاربردهای حساس (پزشکی، حقوقی و آکادمیک) به شدت کاهش می‌دهد.
- **محدودیت پنجره بافت^{۳۲}: (Context Window)** مدل‌ها محدودیت حافظه کوتاه‌مدت در پردازش توکن‌ها دارند و تنها می‌توانند حجم مشخصی از متن (مثلاً ۸K یا ۱۲۸K توکن) را در هر تعامل پردازش و تحلیل کنند.

۳-۲ تولید افزوده شده با بازیابی^{۳۳} (RAG)

برای غلبه بر چالش‌های ذاتی مدل‌های زبانی، معماری تولید افزوده شده با بازیابی معرفی شد. معماری کلاسیک RAG مکانیزم‌های جستجوی اطلاعات را با قدرت تولید متن مدل‌های زبانی ترکیب می‌کند و از دو بخش اصلی تشکیل شده است:

۱. **بازیاب^{۳۴}: (Retriever)** ابتدا پرسش کاربر با استفاده از یک مدل جاسازی^{۳۵} (Embedding Model) به یک بردار ریاضی چگال^{۳۶} در فضای ابعاد بالا تبدیل می‌شود. سپس در

²⁶Prompt Engineering

²⁷Hallucination

²⁸Static Knowledge

²⁹Knowledge Cut-off

³⁰Lack of Attribution

³¹Reliability

³²Context Window

³³Retrieval-Augmented Generation

³⁴Retriever

³⁵Embedding Model

³⁶Dense Vector

یک پایگاه داده برداری^{۳۷} که حاوی اسناد متنی برداری شده است، جستجوی همسایگی (مانند *Cosine Similarity*) انجام شده و $Top - k$ سند مرتبط از نظر معنایی^{۳۸} بازیابی می شود.

۲. تولیدکننده^{۳۹}: **(Generator)** اسناد بازیابی شده به عنوان «بافت خارجی^{۴۰}» به همراه پرسش اصلی کاربر، در قالب یک پرامپت ساختاریافته به LLM تزریق می شوند. مدل زبانی اکنون موظف است پاسخ را منحصراً بر اساس این اطلاعات ارائه شده تولید کند.

این رویکرد ترکیبی، پدیده توهم را به شدت مهار کرده، نیاز به آموزش مجدد مدل^{۴۱} برای تزریق دانش جدید را از بین برده و امکان ارجاع دقیق به منابع را فراهم می سازد.

۴-۲ تفاوت RAG کلاسیک با RAG مبتنی بر وب (چالش های اساسی)

معماری RAG در ابتدا برای پایگاه دانش های ایستا، ساختاریافته و سازمانی (مانند مجموعه ای از فایل های اسناد محلی) طراحی شد. اما پیاده سازی این الگو بر روی گستره نامتناهی «وب» چالش های فنی متفاوتی را به همراه دارد:

- **پویایی و مقیاس پذیری^{۴۲}**: محیط وب دائماً و در کسری از ثانیه در حال تغییر است. بنابراین نمی توان کل آن را در یک دیتابیس برداری محلی ذخیره و به روزرسانی کرد.
- **ناهمگنی و نویز اطلاعات^{۴۳}**: صفحات وب دارای ساختارهای متغیر، تبلیغات، اطلاعات نامعتبر، بدافزارها و سوگیری^{۴۴} هستند. سنجش اعتبار منبع و استخراج متن خالص^{۴۵} (Boilerplate Removal) یک ضرورت پیچیده در این محیط است.
- **نیاز به تفکیک پرسش ها^{۴۶} (Query): (Decomposition)** در محیط وب، پاسخ به یک سؤال تحلیلی معمولاً در یک سند واحد یافت نمی شود. سیستم هوشمند باید بتواند یک سؤال پیچیده را

³⁷Vector Database

³⁸Semantic Similarity

³⁹Generator

⁴⁰External Context

⁴¹Model Retraining

⁴²Dynamism and Scalability

⁴³Heterogeneity and Information Noise

⁴⁴Bias

⁴⁵Boilerplate Removal

⁴⁶Query Decomposition

به چند زیرسؤال شکسته و جستجوهای متعددی^{۴۷} (Multi-hop Retrieval) را به صورت موازی یا متوالی انجام دهد.

۵-۲ سامانه‌های مبتنی بر جستجوی وب (Search-Augmented LLMs) و ابزارهای API

به منظور مقابله با چالش‌های یاد شده، سامانه‌های پیشرفته امروزی از رویکرد تعامل زنده با وب استفاده می‌کنند. این سامانه‌ها برای اتصال به وب از ابزارهای جستجوی مبتنی بر API (مانند Tavily یا Bing Search API) بهره می‌برند که خروجی را به صورت داده‌های ساختاریافته^{۴۸} (غالباً با فرمت JSON) شامل عنوان، پیوند، و محتوای خالص صفحه برمی‌گردانند. مراحل پردازشی در این سامانه‌ها عموماً به شرح زیر است:

۱. بازنویسی پرس‌وجو^{۴۹} (Query Reformulation): مدل زبانی پرسش طبیعی کاربر را تحلیل کرده و آن را به مجموعه‌ای از کلیدواژه‌های بهینه برای موتور جستجو تبدیل می‌کند.

۲. انتخاب منابع^{۵۰} (Source Selection): نتایج خام دریافتی از API ارزیابی شده و سایت‌های نامعتبر یا نتایج نامربوط فیلتر می‌شوند.

۳. استدلال چندمرحله‌ای^{۵۱} (Multi-step Reasoning): مدل با بررسی اولیه متون متوجه می‌شود که آیا اطلاعات یافت شده برای پاسخ کامل کافی است یا خیر. در صورت نقص اطلاعات، پرسش‌های جدیدی تولید و فاز جستجو تکرار می‌گردد.

۴. تولید ارجاعات^{۵۲} (Citation Generation): در گام نهایی، مدل زبانی در حین تولید پاسخ، با استفاده از شناسه‌های یکتا^{۵۳} مشخص می‌کند که هر ادعا از کدام پیوند استخراج شده است.

⁴⁷Multi-hop Retrieval

⁴⁸Structured Data

⁴⁹Query Reformulation

⁵⁰Source Selection

⁵¹Multi-step Reasoning

⁵²Citation Generation

⁵³Unique Identifiers

۶-۲ نقش تاریخچه گفتگو در پاسخ‌گویی محاوره‌ای

یکی از ارکان اساسی سامانه‌های دستیار هوشمند مدرن، حفظ حالت محاوره‌ای^{۵۴} (Conversational) است. در یک گفتگوی چندنوبتی^{۵۵}، کاربران تمایل دارند از ضمائر اشاره استفاده کنند یا سؤالات خود را با فرض آگاهی سیستم از مکالمات قبلی مطرح نمایند (مثلاً پس از پرسش در مورد یک کشور، می‌پرسند: «پایتخت آن کجاست؟»). بدون مدیریت دقیق تاریخچه^{۵۶} (History)، سؤال فعلی کاربر به تنهایی فاقد معنای کامل بوده و موتور جستجو را گمراه می‌کند. در این سامانه‌ها، تاریخچه گفتگو به عنوان یک بافتار کمکی^{۵۷} به مدل زبانی داده می‌شود تا بازنویسی پرسش وابسته به زمینه^{۵۸} را به درستی انجام دهد. از آنجا که محدودیت پنجره بافت مانع از ارسال کل مکالمات طولانی می‌شود، تکنیک‌هایی نظیر خلاصه‌سازی تاریخچه^{۵۹} متداول است.

۷-۲ بازرتبه‌بندی^{۶۰} یا Re-ranking

موتورهای جستجو و API‌های وب به دلیل نیاز به پاسخ‌گویی در مقیاس میلی‌ثانیه، معمولاً از مدل‌های رمزگذار دوگانه^{۶۱} (Bi-Encoders) یا تطابق دقیق کلمات^{۶۲} استفاده می‌کنند. در این روش‌ها، پرسش و سند به صورت مستقل برداری می‌شوند. خروجی اولیه این موتورها ممکن است صدها سند را بازگرداند که همگی مرتبط به نظر می‌رسند اما از نظر معنایی دقیقاً پاسخگوی سؤال پیچیده کاربر نیستند.

برای حل این مشکل، از مفهوم رتبه‌بندی مجدد^{۶۳} با استفاده از مدل‌های رمزگذار متقاطع^{۶۴} (Cross-Encoders) استفاده می‌شود. این مدل‌های یادگیری عمیق، پرسش کاربر و متن سند را به صورت همزمان دریافت کرده و توجه (Attention) را در سطح کلمه-به-کلمه بین پرسش و سند محاسبه می‌کنند. به دلیل بار محاسباتی بالا، معماری استاندارد بدین شکل است که ابتدا تعداد زیادی سند (مثلاً ۱۰۰ مورد) با سرعت بالا بازیابی شده، و سپس توسط Reranker مرتب‌سازی مجدد می‌شوند تا تنها $Top - k$ سند نهایی (مثلاً ۵ مورد با بالاترین امتیاز) برای تولید پاسخ به LLM ارسال گردند.

⁵⁴ Conversational State

⁵⁵ Multi-turn Dialogue

⁵⁶ History

⁵⁷ Auxiliary Context

⁵⁸ Context-dependent Query Rewriting

⁵⁹ History Summarization

⁶⁰ Re-ranking

⁶¹ Bi-Encoders

⁶² Exact Lexical Match

⁶³ Re-ranking

⁶⁴ Cross-Encoders

۸-۲ معیارهای ارزیابی سامانه‌ها^{۶۵}

برای سنجش علمی و کمی عملکرد سامانه‌های جستجو محور هوشمند، ارزیابی باید به صورت تفکیک شده در دو سطح «موتور بازیابی» و «موتور تولید پاسخ» انجام شود. مهم‌ترین معیارهای استاندارد ارزیابی عبارتند از:

- **دقت^{۶۶} (Precision) و فراخوانی^{۶۷}: (Recall)** معیارهای کلاسیک ارزیابی بازیابی. دقت نشان می‌دهد چه کسری از اسناد بازیابی شده واقعاً مرتبط بوده‌اند و فراخوانی نشان‌دهنده کسر اسناد مرتبط بازیابی شده نسبت به کل اسناد مرتبط موجود است.
- **صحت ارجاع^{۶۸} (Citation Accuracy) / Faithfulness** معیاری نوین برای بررسی اینکه آیا پاسخ نهایی تولید شده توسط مدل زبانی، کاملاً و صرفاً از اسناد ارائه شده استنتاج شده است یا خیر (سنجش مستقیم نرخ کاهش توهم).
- **سودمندی^{۶۹} (Answer Relevance):** بررسی میزان تطابق پاسخ نهایی با نیت اصلی کاربر و رفع نیاز اطلاعاتی وی بدون اضافه‌گویی.
- **نرخ برخورد^{۷۰} (Hit Rate) و میانگین رتبه متقابل^{۷۱}: (MRR)** بررسی این موضوع که آیا در میان نتایج اولیه (مثلاً ۱۰ - Top) حداقل یک سند حاوی پاسخ طلایی^{۷۲} وجود داشته است و در چه رتبه‌ای قرار دارد.

این معیارهای کمی و کیفی پایه‌های نظری لازم برای طراحی آزمایش‌ها، پیکربندی بهینه هایپرپارامترها^{۷۳} و اثبات کارایی سامانه‌ی پیشنهادی در فصول آتی را فراهم می‌آورند.

⁶⁵System Evaluation Metrics

⁶⁶Precision

⁶⁷Recall

⁶⁸Citation Accuracy / Faithfulness

⁶⁹Answer Relevance

⁷⁰Hit Rate

⁷¹Mean Reciprocal Rank

⁷²Golden Answer

⁷³Hyperparameters

فصل ۳

کارهای پیشین

در فصل سوم پایان نامه، کارهای پیشین انجام شده روی مسئله به تفصیل توضیح داده می شود. نمونه ای از فصل کارهای پیشین در زیر آمده است.^۱

۳-۱ مسائل خوشه بندی

مسئله ی خوشه بندی^۲ یکی از مهم ترین مسائل در زمینه ی داده کاوی به حساب می آید. در این مسئله، هدف دسته بندی تعدادی شیء به گونه ای است که اشیاء درون یک دسته (خوشه)، نسبت به یکدیگر در برابر دسته های دیگر شبیه تر باشند (معیارهای متفاوتی برای تشابه تعریف می گردد). این مسئله در حوزه های مختلفی از علوم کامپیوتر از جمله داده کاوی، جست و جوی الگو^۳، پردازش تصویر^۴، بازیابی اطلاعات^۵ و رایانش زیستی^۶ مورد استفاده قرار می گیرد [۱].

تا کنون راه حل های زیادی برای این مسئله ارائه شده است که از لحاظ معیار تشخیص خوشه ها و نحوه ی انتخاب یک خوشه، با یکدیگر تفاوت بسیاری دارند. به همین خاطر مسئله ی خوشه بندی یک مسئله ی بهینه سازی چندهدفه^۷ محسوب می شود.

همان طور که در مرجع [۲] ذکر شده است، خوشه در خوشه بندی تعریف واحدی ندارد و یکی از

^۱ مطالب این فصل نمونه از پایان نامه ی آقای بهنام حاتمی گرفته شده است.

^۲ Clustering

^۳ Pattern recognition

^۴ Image analysis

^۵ Information retrieval

^۶ Bioinformatics

^۷ Multi-objective

دلایل وجود الگوریتم‌های متفاوت، همین تفاوت تعریف‌ها از خوشه است. بنابراین با توجه به مدلی که برای خوشه‌ها ارائه می‌شود، الگوریتم متفاوتی نیز ارائه می‌گردد. در ادامه به بررسی تعدادی از معروف‌ترین مدل‌های مطرح می‌پردازیم:

- **مدل‌های مرکزگرا:** در این مدل‌ها، هر دسته با یک مرکز نشان داده می‌شود. از جمله معروف‌ترین روش‌های خوشه‌بندی بر اساس این مدل، خوشه‌بندی k -مرکز، خوشه‌بندی k -میانگین^۸ و خوشه‌بندی k -میان^۹ است.

- **مدل‌های مبتنی بر توزیع نقاط:** در این مدل، دسته‌ها با فرض پیروی از یک توزیع احتمالی مشخص می‌شوند. از جمله الگوریتم‌های معروف ارائه شده در این مدل، الگوریتم بیشینه‌سازی امید ریاضی^{۱۰} است.

- **مدل‌های مبتنی بر تراکم نقاط:** در این مدل، خوشه‌ها متناسب با ناحیه‌های متراکم نقاط در مجموعه داده مورد استفاده قرار می‌گیرد.

- **مدل‌های مبتنی بر گراف:** در این مدل، هر خوشه به مجموعه از رئوس گفته می‌شود که تمام رئوس آن با یک‌دیگر همسایه باشند. از جمله الگوریتم‌های معروف این مدل، الگوریتم خوشه‌بندی HCS^{۱۱} است.

الگوریتم‌های ارائه شده تنها از نظر نوع مدل با یک‌دیگر متفاوت نیستند. بلکه، می‌توان آن‌ها را از لحاظ نحوه‌ی تخصیص نقاط بین خوشه‌ها نیز تقسیم‌بندی کرد:

- **تخصیص قطعی داده‌ها:** در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

- **تخصیص قطعی داده‌ها با داده‌ی پرت:** در این نوع خوشه‌بندی ممکن است بعضی از داده‌ها به هیچ خوشه‌ای اختصاص نیابد، اما بقیه داده‌ها هر کدام دقیقاً به یک خوشه اختصاص می‌یابد.

- **تخصیص قطعی داده:** در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

- **خوشه‌بندی هم‌پوشان:** در این نوع خوشه‌بندی هر داده می‌تواند به چند خوشه اختصاص داده شود. در گونه‌ای از این مدل، می‌توان هر نقطه را با احتمالی به هر خوشه اختصاص می‌یابد. به این گونه از خوشه‌بندی، خوشه‌بندی نرم^{۱۲} گفته می‌شود.


^۸ k -Means

^۹ k -Median

^{۱۰} Expectation-maximization

^{۱۱} Highly Connected Subgraphs

^{۱۲} Soft clustering



شکل ۳-۱: نمونه‌ای از مسئله‌ی ۲-مرکز

• خوشه‌بندی سلسه‌مراتبی: در این نوع خوشه‌ها، داده‌ها به گونه‌ای به خوشه‌ها تخصیص داده می‌شود که دو خوشه یا اشتراک ندارند یا یکی به طور کامل دیگری را می‌پوشاند. در واقع در بین خوشه‌ها، رابطه‌ی پدر فرزندی برقرار است.


در بین دسته‌بندی‌های ذکر شده، تمرکز اصلی این پایان‌نامه بر روی مدل مرکزگرا و خوشه‌بندی قطعی با داده‌های پرت با مدل k -مرکز است. همان‌طور که ذکر شد علاوه بر مسئله‌ی k -مرکز که به تفصیل مورد بررسی قرار می‌گیرد، k -میانه و k -میانگین از جمله معروف‌ترین خوشه‌بندی‌های مدل مرکزگرا هستند. در خوشه‌بندی k -میانه، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع مربع فاصله‌ی هر نقطه از میانه‌ی نقاط آن خوشه، کمینه گردد. در خوشه‌بندی k -میانگین، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع فاصله‌ی هر نقطه از میانگین نقاط داخل خوشه (یا مرکز آن خوشه) کمینه گردد.

۳-۲ خوشه‌بندی k -مرکز

یکی از رویکردهای شناخته‌شده برای مسئله‌ی خوشه‌بندی، مسئله‌ی k -مرکز است. در این مسئله هدف، پیدا کردن k نقطه به عنوان مرکز دسته‌ها است به‌طوری‌که شعاع دسته‌ها تا حد ممکن کمینه شود. مثالی از مسئله‌ی ۲-مرکز در شکل ۳-۱ نشان داده شده است. در این پژوهش، مسئله‌ی k -مرکز با متریک‌های خاص و برای k های کوچک مورد بررسی قرار گرفته است و هر کدام از تعریف رسمی مسئله‌ی k -مرکز در زیر آمده است:

مسئله‌ی ۳-۱ (k -مرکز) گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d ، که از نامساوی مثلثی پیروی می‌کند داده شده است. زیرمجموعه‌ی $S \subseteq V$ با اندازه‌ی k را به گونه‌ای انتخاب کنید که عبارت زیر را کمینه کند:

$$\max_{v \in V} \{ \min_{s \in S} d(v, s) \} \quad (۳-۱)$$



شکل ۲-۳: نمونه‌ای از مسئله‌ی ۲-مرکز با داده‌های پرت

گونه‌های مختلفی از مسئله‌ی k -مرکز با محدودیت‌های متفاوت توسط پژوهشگران مورد مطالعه قرار گرفته است. از جمله‌ی این گونه‌ها، می‌توان به حالتی که در بین داده‌های ورودی، داده‌های پرت وجود دارد، اشاره کرد. در واقع در این مسئله، قبل از خوشه‌بندی می‌توانیم تعدادی از نقاط ورودی را حذف نموده و سپس به خوشه‌بندی نقاط پردازیم. سختی این مسئله از آنجاست که نه تنها باید مسئله‌ی خوشه‌بندی را حل نمود، بلکه در ابتدا باید تصمیم گرفت که کدام یک از داده‌ها را به عنوان داده‌ی پرت در نظر گرفت که بهترین جواب در زمان خوشه‌بندی به دست آید. در واقع اگر تعداد نقاط پرتی که مجاز به حذف است، برابر صفر باشد، مسئله به مسئله‌ی k -مرکز تبدیل می‌شود. نمونه‌ای از مسئله‌ی ۲-مرکز با ۷ داده‌ی پرت را در شکل ۲-۳ می‌توانید ببینید. تعریف دقیق‌تر این مسئله در زیر آمده است:

مسئله‌ی ۲-۳ (k -مرکز با داده‌های پرت) یک گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d ، که از نامساوی مثلثی پیروی می‌کند داده شده است. زیرمجموعه‌ی $Z \subseteq V$ با اندازه‌ی z و مجموعه‌ی $S \subseteq V - Z$ با اندازه‌ی k را انتخاب کنید به طوری که عبارت زیر را کمینه کند:

$$\max_{v \in V-Z} \{ \min_{s \in S} d(v, s) \} \quad (2-3)$$

گونه‌ی دیگری از مسئله‌ی k -مرکز که در سال‌های اخیر مورد توجه قرار گرفته است، حالت جویبار داده‌ی آن است. در این گونه از مسئله‌ی k -مرکز، در ابتدا تمام نقاط در دسترس نیستند، بلکه به مرور زمان نقاط در دسترس قرار می‌گیرند. محدودیت دومی که وجود دارد، محدودیت حافظه است، به طوری که نمی‌توان تمام نقاط را در حافظه نگه داشت و بعضاً حتی امکان نگه‌داری در حافظه‌ی جانبی نیز وجود ندارد و به طور معمول باید مرتبه‌ی حافظه‌ای کم‌تر از مرتبه حافظه‌ی خطی^{۱۳} متناسب با تعداد نقاط استفاده نمود. از این به بعد به چنین مرتبه‌ای، مرتبه‌ی زیرخطی^{۱۴} می‌گوییم. مدلی که ما در این پژوهش بر روی آن تمرکز داریم مدل جویبار داده تک‌گذره^{۱۵} [۳] است. یعنی تنها یک بار می‌توان از ابتدا تا انتهای داده‌ها را بررسی کرد و پس

^{۱۳} Linear
^{۱۴} sublinear
^{۱۵} Single pass

از عبور از یک داده، اگر آن داده در حافظه ذخیره نشده باشد، دیگر به آن دسترسی وجود ندارد. علاوه بر این، در هر لحظه باید بتوان به پرسمان (برای تمام نقاطی از جویبار داده که تاکنون به آن دسترسی داشته‌ایم) پاسخ داد.

مسئله ۳-۳ (k -مرکز در حالت جویبار داده) مجموعه‌ای از نقاط در فضای d -بعدی به مرور زمان داده می‌شود. در هر لحظه از زمان، به ازای مجموعه‌ی U از نقاطی که تا کنون وارد شده‌اند، زیرمجموعه‌ی $S \subseteq U$ با اندازه‌ی k را انتخاب کنید به طوری که عبارت زیر کمینه شود:

$$\max_{u \in U} \{ \min_{s \in S} d(u, s) \} \quad (3-3)$$

از آنجایی که گونه‌ی جویبار داده و داده پرت مسئله‌ی k -مرکز به علت به‌روز بودن مبحث داده‌های حجیم^{۱۶}، به تازگی مورد توجه قرار گرفته است. در این تحقیق سعی شده است که تمرکز بر روی این گونه‌ی خاص از مسئله باشد. همچنین در این پژوهش سعی می‌شود گونه‌های مسئله را برای انواع متریک‌ها و برای k های کوچک نیز مورد بررسی قرار داد.

۳-۳ مدل جویبار داده

همان‌طور که ذکر شد مسئله‌ی k -مرکز در حالت داده‌های پرت و جویبار داده، گونه‌های تعمیم‌یافته از مسئله‌ی k -مرکز هستند و در حالت‌های خاص به مسئله‌ی k -مرکز کاهش پیدا می‌کنند. مسئله‌ی k -مرکز در حوزه‌ی مسائل ان‌پی-سخت^{۱۷} قرار می‌گیرد و با فرض $P \neq NP$ الگوریتم دقیق با زمان چندجمله‌ای برای آن وجود ندارد [۴]. بنابراین برای حل کارای^{۱۸} این مسائل از الگوریتم‌های تقریبی^{۱۹} استفاده می‌شود.

برای مسئله‌ی k -مرکز، دو الگوریتم تقریبی معروف وجود دارد. در الگوریتم اول، که به روش حریصانه^{۲۰} عمل می‌کند، در هر مرحله بهترین مرکز ممکن را انتخاب می‌کند به طوری تا حد ممکن از مراکز قبلی دور باشد [۵]. این الگوریتم، الگوریتم تقریبی با ضریب تقریب ۲ ارائه می‌دهد. در الگوریتم دوم، با استفاده از مسئله‌ی مجموعه‌ی غالب کمینه^{۲۱}، الگوریتمی با ضریب تقریب ۲ ارائه می‌گردد [۶]. همچنین ثابت شده است، که بهتر از این ضریب تقریب، الگوریتمی نمی‌توان ارائه داد مگر آن‌که $P = NP$ باشد.

^{۱۶} Big data

^{۱۷} NP-hard

^{۱۸} Efficient

^{۱۹} Approximation algorithm

^{۲۰} Greedy

^{۲۱} Dominating set

جدول ۳-۱: نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی

مسئله	کران پایین تقریب‌پذیری
k - مرکز	۲ [۶]
k - مرکز در فضای اقلیدسی	۱/۸۲۲ [۱۵]
۱ - مرکز در حالت جویبار داده	$\frac{1+\sqrt{2}}{4}$ [۱۱]
k - مرکز با نقاط پرت و نقاط اجباری	۳ [۱۰]

برای مسئله‌ی k - مرکز در حالت جویبار داده برای ابعاد بالا، بهترین الگوریتم موجود ضریب تقریب $2 + \varepsilon$ دارد [۷، ۸، ۹] و ثابت می‌شود الگوریتمی با ضریب تقریب بهتر از ۲ نمی‌توان ارائه داد. برای مسئله‌ی k - مرکز با داده‌ی پرت در حالت جویبار داده نیز، بهترین الگوریتم ارائه شده، الگوریتمی با ضریب تقریب $4 + \varepsilon$ است که با کران پایین ۳ هنوز اختلاف قابل توجهی دارد [۱۰].

برای k های کوچک به خصوص، $k = 1, 2$ ، الگوریتم‌های بهتری ارائه شده است. بهترین الگوریتم ارائه شده برای مسئله‌ی ۱ - مرکز در حالت جویبار داده برای ابعاد بالا، دارای ضریب تقریب $1/22$ است و کران پایین $\frac{1+\sqrt{2}}{4}$ نیز برای این مسئله اثبات شده است [۱۱، ۱۲]. برای مسئله ۲ - مرکز در حالت جویبار داده برای ابعاد بالا، اخیراً راه‌حلی با ضریب تقریب $1/8 + \varepsilon$ ارائه شده است [۱۳]. برای مسئله‌ی ۱ - مرکز با داده‌ی پرت، تنها الگوریتم موجود، الگوریتمی با ضریب تقریب $1/73$ است [۱۴].

۳-۴ تقریب‌پذیری

یکی از راه‌کارهایی که برای کارآمد کردن راه‌حل ارائه شده برای یک مسئله وجود دارد، استفاده از الگوریتم‌های تقریبی برای حل آن مسئله است. یکی از عمده‌ترین دغدغه‌های مطرح در الگوریتم‌های تقریبی کاهش ضریب تقریب است. در بعضی از موارد حتی امکان ارائه‌ی الگوریتم تقریبی با ضریبی ثابت نیز وجود ندارد. به طور مثال، الگوریتم تقریبی با ضریب تقریب کم‌تر از ۲، برای مسئله‌ی k - مرکز وجود ندارد مگر این‌که $P = NP$ باشد. برای مسائل مختلف، معمولاً می‌توان کران پایینی برای میزان تقریب‌پذیری آن‌ها ارائه داد. در واقع برای برخی مسائل ان‌پی-سخت، علاوه بر این که الگوریتم کارآمدی وجود ندارد، بعضاً الگوریتم تقریبی با ضریبی تقریب کم و نزدیک به یک نیز وجود ندارد. در جدول ۳-۱ میزان تقریب‌پذیری مسائل مختلفی که در این پایان‌نامه مورد استفاده قرار می‌گیرد را می‌بینید.

فصل ۴

نتایج جدید

در این فصل نتایج جدید به دست آمده در پایان نامه توضیح داده می شود. در صورت نیاز می توان نتایج جدید را در قالب چند فصل ارائه نمود. همچنین در صورت وجود پیاده سازی، بهتر است نتایج پیاده سازی را در فصل مستقلی پس از این فصل قرار داد.

فصل ۵

نتیجه‌گیری

در این فصل، ضمن جمع‌بندی نتایج جدید ارائه‌شده در پایان‌نامه یا رساله، مسائل باز باقی‌مانده و همچنین پیشنهادهایی برای ادامه‌ی کار ارائه می‌شوند.

Bibliography

- [1] J. Han and M. Kamber. *Data Mining, Southeast Asia Edition: Concepts and Techniques*. Morgan kaufmann, 2006.
- [2] V. Estivill-Castro. Why so many clustering algorithms: a position paper. *ACM SIGKDD explorations newsletter*, 4(1):65–75, 2002.
- [3] C. C. Aggarwal. *Data streams: models and algorithms*. Springer Science & Business Media, 2007.
- [4] M. R. Garey and D. S. Johnson. Computers and intractability: a guide to the theory of NP-completeness. *Freeman & Co.*, 1979.
- [5] N. Megiddo and K. J. Supowit. On the complexity of some common geometric location problems. *SIAM Journal on Computing*, 13(1):182–196, 1984.
- [6] V. V. Vazirani. *Approximation Algorithms*. Springer-Verlag New York, Inc., 2001.
- [7] R. M. McCutchen and S. Khuller. Streaming algorithms for k-center clustering with outliers and with anonymity. In *Proceedings of the 11th International Workshop on Approximation Algorithms*, pages 165–178, 2008.
- [8] S. Guha. Tight results for clustering and summarizing data streams. In *Proceedings of the 12th International Conference on Database Theory*, pages 268–275, 2009.
- [9] H.-K. Ahn, H.-S. Kim, S.-S. Kim, and W. Son. Computing k centers over streaming data for small k. *International Journal of Computational Geometry and Applications*, 24(02):107–123, 2014.
- [10] M. Charikar, S. Khuller, D. M. Mount, and G. Narasimhan. Algorithms for facility location problems with outliers. In *Proceedings of the 12th ACM-SIAM Symposium on Discrete Algorithms*, pages 642–651, 2001.

- [11] P. K. Agarwal and R. Sharathkumar. Streaming algorithms for extent problems in high dimensions. In *Proceedings of the 21st ACM-SIAM Symposium on Discrete Algorithms*, pages 1481–1489, 2010.
- [12] T. M. Chan and V. Pathak. Streaming and dynamic algorithms for minimum enclosing balls in high dimensions. *Computational Geometry: Theory and Applications*, 47(2):240–247, 2014.
- [13] S.-S. Kim and H.-K. Ahn. An improved data stream algorithm for clustering. In *Proceedings of the 11th Latin American Symposium on Theoretical Informatics*, pages 273–284, 2014.
- [14] H. Zarrabi-Zadeh and A. Mukhopadhyay. Streaming 1-center with outliers in high dimensions. In *Proceedings of the 21st Canadian Conference on Computational Geometry*, pages 83–86, 2009.
- [15] M. Bern and D. Eppstein. Approximation algorithms for geometric problems. In D. S. Hochbaum, editor, *Approximation Algorithms for NP-hard Problems*, pages 296–345. PWS Publishing Co., 1997.

واژه‌نامه

الف

experimental تجربی	heuristic ابتکاری
density تراکم	high dimensions ابعاد بالا
approximation تقریب	bias اریب
partition تقسیم‌بندی	threshold آستانه
mesh توری	pigeonhole principle اصل لانه‌ی کبوتری
distributed توزیع‌شده	NP-Hard ان‌پی-سخت
	transition انتقال

ت

ج

separable جداپذیر
black box جعبه سیاه
data stream جویبار داده

ح

extreme حدی
greedy حریصانه

خ

cluster خوشه
linear خطی

ب

online برخط
linear programming برنامه‌ریزی خطی
optimum بهینه
maximum بیشینه

پ

outlier پرت
query پرسمان
cover پوشش
complexity پیچیدگی

د

داده data
داده کاوی data mining
داده‌ی پرت outlier data
دو برابر سازی doubling
دودویی binary

ف

فاصله distance
فضا space

ق

قطعی deterministic

ر

رأس vertex
رسمی formal

ک

کارا efficient
کاندیدا candidate
کمینه minimum

ز

زیرخطی sublinear

م

مجموعه set
مجموعه هسته coreset
سطح planar
موازی سازی parallelization
میان گیر buffer

س

سرشکن amortized
سلسله مراتبی hierarchichal

ش

شبه کد pseudocode
شیء object

ن

نابه جایی inversion
ناوردا invariant
نقطه‌ی مرکزی center point
نیم فضا half space

ص

صدق پذیری satisfiability

ه

هزینه‌ی آشوب price of anarchy (POA)

غ

غلبه dominate

ی

یال edge

پیوست آ

مطالب تکمیلی

پیوست‌های خود را در صورت وجود می‌توانید در این قسمت قرار دهید.

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the X_YPersian package for the L^AT_EX typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, X_YPersian



Sharif University of Technology
Department of Computer Engineering

B.Sc. Thesis

Intelligent Web Search Engine

By:

Ali Hashemian

Supervisor:

Dr. Hamid Beigi

June 2026